

فهرست مطالب

۱	چکیده	فصل ۱:
۳	مروری بر مطالعات انجام شده	فصل ۲:
۳	مقدمه	۱.۲
۴	روش‌های اولیه	۲.۲
۶	شبکه‌های عصبی و یادگیری عمیق	۳.۲
۱۰	مدل‌های ترنسفورمر	۴.۲
۱۲	منابع	۵.۲
۱۷	روش‌ها	فصل ۳:
۱۷	مقدمه	۱.۳
۱۷	تغییر اندازه و نرمال‌سازی تصاویر	۲.۳
۲۰	بهبود بینایی ماشین با ادغام درک معنایی، استدلال شناختی و روان‌فیزیک	۳.۳
۲۳	ارزیابی تأثیر شرایط آب‌وهوایی شبیه‌سازی شده بر عملکرد مدل	۴.۳
۲۳	خلاصه‌ای بر مفاهیم پردازش تصویر	۵.۳
۲۴	افکت باران (Rain)	۱.۵.۳
۲۴	افکت برف (Snow)	۲.۵.۳
۲۵	افکت مه (Fog)	۳.۵.۳
۲۵	افکت باد (Wind)	۴.۵.۳
۲۵	افکت نور خورشید (Sunlight)	۵.۵.۳

۶.۵.۳	روش های اعمال فیلترها	۲۶
۷.۵.۳	تأثیر فیلترها بر مدل	۲۶
۸.۵.۳	درصد اعمال فیلترها	۲۶
۶.۳	ضرورت افزایش داده ها و مدیریت عدم تعادل	۲۷
۱.۶.۳	نسبت عدم تعادل و ارتباط آن با افزایش داده ها	۲۷
۲.۶.۳	فلوچارت الگوریتم SMOTE	۲۷
۳.۶.۳	فلوچارت وزن دهی در تابع هزینه	۲۷
۷.۳	مروری بر روش های افزایش داده	۲۸
۸.۳	معیارهای ارزیابی و مقایسه روش ها	۳۱
۱.۸.۳	MobileNetV2	۳۵
۲.۸.۳	EfficientNet	۳۶
۳.۸.۳	ResNet	۳۷
۴.۸.۳	ساختار معماری و اجزای اصلی	۳۸
۵.۸.۳	مکانیزم آموزش و روش های ارزیابی	۳۹
۴۱	نتایج	
۱.۴	معرفی مجموعه داده	۴۱
۱.۱.۴	ضرورت انتخاب دیتاست مناسب	۴۱
۲.۴	بررسی و تحلیل دیتاست ها	۴۲
۱.۲.۴	دلایل انتخاب و عدم انتخاب دیتاست ها	۴۶
۳.۴	تحلیل ویژگی های آماری	۴۷
۱.۳.۴	دسته بندی معنایی و بصری	۴۸
۲.۳.۴	تحلیل تنوع و عدم تعادل داده ها	۵۳
۱.۲.۳.۴	نمودار توزیع نمونه ها در کلاس ها	۵۳
۲.۲.۳.۴	تحلیل عدم تعادل داده ها	۵۴
۴.۴	متعادل سازی داده ها با استفاده از تکنیک های افزایش داده	۵۸

۶۰	متعادل سازی در سطح دسته بندی های معنایی و بصری	۱.۴.۴
۶۱	پیش پردازش داده ها	۵.۴
۶۳	مقایسه عملکرد مدل ها	۶.۴
۶۳	مقایسه معیارهای عملکرد مدل ها	۱.۶.۴
۶۴	ماتریس های اشتباه (Confusion Matrices)	۲.۶.۴
۶۶	نتایج تاثیر شبیه سازی شرایط جوی مختلف بر روی تصاویر	۷.۴
۶۷	نتایج و مقایسه	۱.۷.۴
۶۸	پیاده سازی فیلترهای محیطی در تصاویر و نحوه عملکرد آنها	۲.۷.۴
۶۹	نحوه اجرای فیلترها	۳.۷.۴
۶۹	خلاصه عملکرد فیلترها	۴.۷.۴

فصل ۱

چکیده

در عصر تحولات شتابان فناوریهای خودران، سیستمهای بینایی ماشین به عنوان یکی از ارکان حیاتی در ادراک محیطی خودروها نقش ایفا میکنند. پروژه حاضر با تمرکز بر بهبود عملکرد سیستمهای تشخیص علائم راهنمایی و رانندگی، تلاشی هدفمند برای تقریب هرچه بیشتر رفتار این سیستمها به قابلیتهای انسانی است. اهمیت این موضوع در شرایط واقعی رانندگی خودمختار، که کوچکترین خطا در تشخیص علائم میتواند پیامدهای جبرانناپذیری داشته باشد، بیش از پیش آشکار میشود. در این راستا، پژوهش ما با بهره‌گیری از مدل‌های پیشرفته هوش مصنوعی و بینایی کامپیوتر، رویکردی تحلیلی-معنایی را برای درک عمیق‌تر ویژگیهای علائم راهنمایی و رانندگی طراحی کرده است. مطالعه گسترده و نظام‌مند پژوهشهای پیشین، نخستین گام این پروژه بود. با بررسی انتقادی کارهای مرتبط، نقاط قوت و ضعف روشهای موجود شناسایی شد و این تحلیل به انتخاب هوشمندانه‌ترین مجموعه داده متناسب با اهداف و محدودیتهای پروژه منجر گردید. در گام بعدی، با تمرکز بر درک جامع مجموعه داده انتخابی، ویژگیهای کلیدی علائم از جمله شکل، رنگ، نمادها، و زمینه قرارگیری آنها در محیط واقعی مورد تحلیل قرار گرفتند. رویکرد این پژوهش صرفاً به حجم انبوه داده‌ها متکی نبود، بلکه با تأکید بر تحلیل معنایی و ارتباط بین ویژگیهای ساختاری علائم (مانند تقارن، تضاد رنگی، و موقعیت مکانی) و نقش آنها در انتقال پیام به رانندگان، لایهای جدید از هوشمندی را به سیستم افزود. یکی از نوآوریهای اصلی این پروژه، شیب‌سازی شرایط پیچیده و غیرایده‌آل محیطی است که علائم در آن قرار میگیرند. با استفاده از ابزارهای تولید داده‌های مصنوعی

(۱) و تکنیکهای افزایش داده (۲)، سناریوهایی مانند تغییرات نورپردازی (۳)، اعوجاجهای دیداری (۴)، و حتی آسیبهای فیزیکی به علائم (۵) مدلسازی شدند. این شبیهسازها نه تنها به بهبود مقاومت (۶) مدل در مواجهه با دادههای واقعی کمک کرد، بلکه امکان ارزیابی عملکرد سیستم در حالات مرزی (۷) را نیز فراهم آورد. در نهایت، مدل پیشنهادی با تلفیق رویکردهای مبتنی بر یادگیری عمیق (۸) (مانند شبکه های کانولوشنی) و پردازشهای معنایی لایه لایه، به سمت سیستمیک سوق داده شد که نه تنها قادر به تشخیص دقیق علائم است، بلکه میتواند با استنتاج منطقی از جایگاه علائم در چارچوب قوانین راهنمایی و رانندگی (۹) (مانند اولویتبندی علائم متضاد)، گامی به سوی "استدلال انسانی" بردارد. ارزیابی نتایج نشان میدهد که این سیستم در مقایسه با روشهای متکی صرف بر حجم داده، از دقت تشخیص بالاتری در شرایط پویا و غیرقابل پیشبینی برخوردار است. این پژوهش مسیری نوین در همگرایی هوش مصنوعی (۱۰)، مهندسی معنایی، و الزامات امنیتی سیستمهای خودران (۱۱) ترسیم میکند و چارچوبی را برای توسعه سیستمهای تشخیص علائم با قابلیت تفسیرپذیری (۱۲) بالا ارائه مینماید.

¹Synthetic Data

²Data Augmentation

³Night/Day, Sun Reflections

⁴Rain, Snow, Fog

⁵Scratches, Dirt

⁶Robustness

⁷Edge Cases

⁸Deep Learning

⁹Traffic Rules

¹⁰AI

¹¹Autonomous Systems

¹²Interpretability

فصل ۲

مروری بر مطالعات انجام شده

۱.۲ مقدمه

سیستم‌های حمل و نقل هوشمند ITS^۱ به عنوان راهکاری برای توسعه روش‌های حمل و نقل کارآمد، ایمن و سازگار با محیط زیست شکل گرفته‌اند. این سیستم‌ها با ترکیب حسگرهای پیشرفته، شبکه‌های ارتباطی، تحلیل داده‌ها و الگوریتم‌های هوشمند طراحی شده‌اند. در مواجهه با چالش‌های پیچیده ناشی از شهرنشینی مدرن، این سیستم‌ها ضروری بوده و راه‌حل‌های نوآورانه‌ای برای کاهش ترافیک، بهبود امنیت و کاهش اثرات منفی زیست‌محیطی ارائه می‌دهند. تشخیص علائم راهنمایی و رانندگی، به عنوان یکی از حوزه‌های کلیدی در سیستم‌های حمل و نقل هوشمند، نقش بسیار مهمی در ارتقای ایمنی جاده‌ها، توسعه خودروهای خودران و بهبود سیستم‌های کنترل ترافیک ایفا می‌کند. این قابلیت می‌تواند به طور قابل توجهی بر ایمنی جاده‌ها و مدیریت ترافیک تأثیرگذار باشد. تشخیص دقیق و به موقع علائم، نقش اساسی در آگاه‌سازی رانندگان از محدودیت‌های سرعت و الزامات قانونی ایفا کرده و در نتیجه ایمنی جاده‌ها را به حداکثر می‌رساند. در رابطه با این موضوع رویکردهای گوناگونی برای مطالعه استفاده شده است [۱].

^۱ITS (Intelligent Transportation Systems)

۲.۲ روش‌های اولیه

روش‌های اولیه عمدتاً بر تحلیل ویژگی‌های رنگ و شکل علائم متمرکز بودند. به عنوان مثال، پیکچولی و همکاران [۲] (۱۹۹۶) با استفاده از رنگ‌های مشخص^۲، نواحی کاندید را شناسایی کرده و از تطبیق الگو برای طبقه‌بندی استفاده می‌کردند. همچنین، زاده، آ. و کاسواند، ب. در ۱۹۹۸ [۳] برای مقاوم‌سازی سیستم در برابر تغییرات مقیاس و زاویه، از تبدیل‌های هندسی^۳ بهره گرفتند. با این حال، این روش‌ها محدودیت‌هایی داشتند و نمی‌توانستند به خوبی با انسداد جزئی و شرایط نوری متغیر کنار بیایند.

برای بهبود عملکرد، روش‌های مبتنی بر شبکه عصبی^۴ معرفی شدند. کلمایر، و. و زواهلن [۴] (۱۹۹۴) از اولین مقالاتی بود که شبکه‌های عصبی را برای تشخیص علائم به کار گرفت. این روش قابلیت یادگیری و تعمیم از داده‌های آموزشی را داشت اما در مواجهه با انسداد و نویز^۵ عملکرد محدودی داشت. در ادامه، اسکالرا و همکاران [۵] (۲۰۰۳) روشی ترکیبی را معرفی کردند که از الگوریتم ژنتیک^۶ برای شناسایی و شبکه‌های عصبی برای طبقه‌بندی استفاده می‌کرد. این روش با مقاومت در برابر تغییرات نور، انسداد جزئی و تغییر شکل علائم، توانست عملکرد بهتری در محیط‌های پیچیده ارائه دهد. در سال ۲۰۰۵، بهلمان و همکاران [۶] یک سیستم جامع و سه مرحله‌ای برای شناسایی، ردیابی و طبقه‌بندی علائم ارائه کردند. در این روش، ابتدا با استفاده از الگوریتم تقویت تطبیقی^۷، ترکیبی از ویژگی‌های رنگی کانال‌های RGB^۸ و نرمال‌شده، ویژگی‌های هندسی (موقعیت، عرض و ارتفاع)، و دیگر پارامترها برای انتخاب قوی‌ترین ویژگی‌ها استفاده شد. سپس، با بهره‌گیری از یک مدل حرکتی ساده و ترکیب اطلاعات زمانی، نواحی شناسایی شده ردیابی شدند. در نهایت، این نواحی نرمال‌سازی شده و طبقه‌بندی با مدل‌های بیزین^۹ انجام گرفت. این سیستم که روی ۴۰۰۰ تصویر آزمایش شد، توانست نرخ طبقه‌بندی ۹۴٪ را بر روی داده‌های آزمون شامل ۱۷۰۰ تصویر به دست آورد. روش بهلمان با افزودن مرحله ردیابی حرکتی و استفاده از مدل‌های بیزین، پایداری و دقت بیشتری را ارائه داد. در حالی که روش اکاسکلرا [۵] به ترکیب الگوریتم ژنتیک و شبکه‌های عصبی تکیه داشت، استفاده از تقویت تطبیقی برای انتخاب ویژگی‌ها و مدل‌های بیزین برای طبقه‌بندی، قابلیت بهتری در مواجهه با مجموعه داده‌های بزرگ و متنوع فراهم کرد. در مقاله

^۲Red, Green, Blue (RGB)

^۳Fourier Transform Basis

^۴Neural Networks

^۵Noise

^۶Genetic Algorithm

^۷Adaptive Boosting (AdaBoost)

^۸Red, Green, Blue

^۹Bayesian Models

گائو و همکاران [۷] (۲۰۰۶)، از دو مدل CIECAM97 و FOSTS برای شناسایی علائم راهنمایی و رانندگی استفاده شد. مدل CIECAM97 اطلاعات رنگی تصاویر را با تبدیل فضای RGB^{۱۰} به HCL^{۱۱} استخراج می‌کرد، در حالی که مدل FOSTS با تقلید از سیستم بینایی انسان، ویژگی‌های شکلی علائم را از طریق تحلیل لبه‌ها و جهت‌گیری‌های تصویر شناسایی می‌کرد. این مدل با استفاده از ساختاری شامل دایره‌های هم‌مرکز و خطوط شعاعی، توانست ویژگی‌های شکلی را با مقاومت در برابر تغییرات مقیاس، چرخش، و تحریف استخراج کند. این سیستم با نرخ شناسایی ۹۵٪ برای ۹۸ تصویر علائم راهنمایی و رانندگی بریتانیایی، عملکرد مطلوبی حتی در شرایط نوری و زاویه‌ای متغیر ارائه داد.

در مقایسه، مالدونادو باسکان و همکاران [۸] (۲۰۱۰) سیستمی مبتنی بر ماشین‌های بردار پشتیبان^{۱۲} توسعه دادند که دقت ۵۰.۹۵٪ را روی پایگاه داده‌ای شامل ۳۶۰۰۰ نمونه از ۱۹۳ کلاس علائم اسپانیایی به دست آورد. این سیستم شامل سه مرحله اصلی بود: قطعه‌بندی علائم با ماسک‌های رنگی در فضای HSI^{۱۳}، تشخیص شکل‌ها با تحلیل FFT^{۱۴} از لبه‌ها، و طبقه‌بندی علائم با ماشین‌های بردار پشتیبان. پیش‌پردازش‌هایی نظیر نرمال‌سازی خاکستری و افزایش کنتراست نیز دقت سیستم را ۳-۵٪ بهبود داد و گروه‌بندی بردارهای پشتیبان تعداد آن‌ها را تا ۷۰٪ کاهش داد، که باعث افزایش کارایی سیستم شد. در همین زمینه، هو و همکاران [۹] (۲۰۱۰) از رویکردی مبتنی بر ویژگی‌های جزئی و مدل کیسه کلمات^{۱۵} استفاده کردند. در این روش، نقاط کلیدی تصویر با الگوریتم تبدیل ویژگی‌های مقیاس‌ناپذیر و چرخش‌ناپذیر^{۱۶} شناسایی و توصیف شدند. ویژگی‌های SIFT به دلیل مقاومت در برابر تغییرات مقیاس، چرخش، زاویه دید و نورپردازی انتخاب شدند. سپس این ویژگی‌ها با الگوریتم خوشه‌بندی^{۱۷} و به فضای کیسه کلمات تبدیل شدند. در نهایت، طبقه‌بندی با ماشین بردار پشتیبان^{۱۸} و هسته تابع پایه شعاعی^{۱۹} انجام شد و پارامترهای C و Γ بهینه‌سازی گردیدند. این روش با دقت ۹۳٪ روی ۱۳۰ تصویر واقعی و زمان پردازش ۰.۹۸ ثانیه برای هر تصویر، عملکردی سریع و مقاوم در برابر تغییرات محیطی ارائه داد. در مقایسه، روش مالدونادو باسکان [۸] به دلیل استفاده از داده‌های گسترده‌تر و پیش‌پردازش پیشرفته‌تر

^{۱۰}Red, Green, Blue^{۱۱}Hue, Chrome, Light^{۱۲}Support Vector Machines (SVM)^{۱۳}Hue, Saturation, Intensity^{۱۴}Fast Fourier Transform^{۱۵}Bag-of-Words (BoW)^{۱۶}Scale-Invariant Feature Transform (SIFT)^{۱۷}K-Means Clustering^{۱۸}Support Vector Machine (SVM)^{۱۹}Radial Basis Function (RBF)

دقت بیشتری داشت، اما روش هو به دلیل زمان پردازش کمتر و انعطاف پذیری در شرایط متغیر برتری نشان داد. همچنین، روش گائو [۷] با تمرکز بر مدل های بینایی انسان و مقاومت در برابر تغییرات، رویکرد متفاوتی ارائه کرد. اما اکثر مدل هایی که نام برده شد در واقع برای مقایسه به طور کامل قابل اعتماد نیستند زیرا بر اساس داده های اختصاصی ارزیابی شده اند که در دسترس عموم نیستند. در سال ۲۰۱۱، استالکمپ مجموعه داده مرجع شناسایی علائم راهنمایی و رانندگی آلمان^{۲۰} را معرفی کرد و به دنبال آن رقابت IJCNN معرفی شد که در آن مدل های مختلفی بر روی این مجموعه داده ارزیابی شد [۱۰].

۳.۲ شبکه های عصبی و یادگیری عمیق

در یکی از نخستین نتایج موفقیت آمیز برای این دیتاست سرمنه، پ. و لکون، ی. (۲۰۱۱) [۱۱]، از شبکه های عصبی کانولوشنی چندمقیاسی^{۲۱} با معماری پیشرفته استفاده شد که ویژگی های جزئی و کلی را از چندین لایه استخراج و برای طبقه بندی ترکیب می کرد. این معماری شامل چندین لایه کانولوشن، لایه های غیرخطی (مانند ReLU)، و لایه های Pooling بود. هر لایه کانولوشن با استفاده از فیلترهایی با اندازه مشخص، ویژگی هایی مانند لبه ها، بافت ها و الگوهای پیچیده تر را استخراج می کرد. لایه های Pooling برای کاهش ابعاد و افزایش مقاومت در برابر تغییرات جزئی مانند جابه جایی و چرخش طراحی شده بودند. علاوه بر این، خروجی های چندین لایه استخراج ویژگی به صورت هم زمان به طبقه بند نهایی وارد می شدند که ترکیبی از اطلاعات جزئی و کلی را فراهم می کرد.

برای افزایش تنوع داده ها، از تکنیک های تقویت داده^{۲۲} مانند چرخش، جابه جایی، تغییر مقیاس و افزودن نویز استفاده شد. این تغییرات به طور تصادفی در هر دوره آموزشی اعمال می شدند و باعث افزایش پنج برابری نمونه های آموزشی و بهبود مقاومت مدل در برابر تغییرات محیطی شدند. این روش توانست دقتی نزدیک به ۹۹٪ را به دست آورد و یکی از موفق ترین کاربردهای اولیه شبکه های عصبی کانولوشنی در این حوزه محسوب می شد.

در ادامه این تلاش ها، یکی از برجسته ترین این روش ها، شبکه های عصبی چندستونه^{۲۳} ارائه شده توسط تیم IDSIA بود [۱۲]. در این روش، چندین شبکه عصبی کانولوشنی به صورت موازی ترکیب شدند تا عملکرد

²⁰German Traffic Sign Recognition Benchmark (GTSRB)

²¹Multi-Scale Convolutional Networks (CNNs)

²²Data Augmentation

²³Multi-Column Deep Neural Networks (MCDNN)

طبقه‌بندی بهبود یابد. این سیستم با استفاده از داده‌های خام و تقویت داده‌ها^{۲۴}، به‌طور هم‌زمان ویژگی‌های سطح پایین و سطح بالا را استخراج می‌کند. در این رویکرد، اعمال تغییرات تصادفی بر روی داده‌ها در هر دوره آموزشی منجر به افزایش تعمیم‌پذیری مدل شد. این روش با دقت ۴۶.۹۹٪، عملکردی فراتر از توانایی انسانی ارائه داد. علاوه بر این، جنگل تصادفی^{۲۵} [۱۳] و تحلیل تفکیکی خطی^{۲۶} [۱۴] نیز برای مقایسه با روش‌های پیچیده‌تر به کار گرفته شدند. جنگل تصادفی با استفاده از ترکیب چندین درخت تصمیم که بر زیرمجموعه‌های مختلف داده‌ها آموزش داده شده بودند، عملکردی پایدار در برابر عدم توازن داده‌ها ارائه کرد. تحلیل تفکیکی خطی، علیرغم سادگی و هزینه محاسباتی پایین، با استفاده از ویژگی‌های هیستوگرام گرادیان‌های جهت‌دار^{۲۷} [۱۵] توانست دقتی بالاتر از ۹۵٪ کسب کند. این نشان می‌داد که حتی مدل‌های کم‌هزینه نیز می‌توانند در شرایط خاص رقابتی باشند. شبکه عصبی کانولوشنی سریع^{۲۸} [۱۶]، به‌عنوان یکی از پیشرفته‌ترین مدل‌های تشخیص اشیاء، در سال ۲۰۱۵ توسط رن و همکاران ارائه شد. این مدل با ترکیب شبکه پیشنهاد منطقه^{۲۹} و شبکه عصبی کانولوشنی در یک چارچوب یکپارچه، امکان تشخیص سریع و دقیق را فراهم کرد. در این مدل، شبکه پیشنهاد منطقه با اسکن تصویر و تولید نواحی پیشنهادی با احتمال بالاتر حضور اشیاء، نقش کلیدی ایفا می‌کند. سپس این نواحی به شبکه عصبی کانولوشنی اصلی ارسال می‌شوند تا ویژگی‌ها استخراج و اشیاء طبقه‌بندی شوند. شبکه عصبی کانولوشنی سریع توانست مشکلات روش‌های قبلی مانند وابستگی به الگوریتم‌های خارجی برای تولید نواحی پیشنهادی را برطرف کرده و دقت و سرعت بیشتری ارائه دهد.

به الگوریتم‌های خارجی برای تولید نواحی پیشنهادی را برطرف کرده و دقت و سرعت بیشتری ارائه دهد. در این پژوهش نیز [۱۷] از Faster R-CNN برای تشخیص علائم راهنمایی استفاده شده است. در این روش، ResNet50 به‌عنوان شبکه استخراج ویژگی انتخاب شده، زیرا لایه‌های عمیق آن قابلیت استخراج ویژگی‌های پیچیده و دقیق را دارند. همچنین، جعبه‌های لنگر^{۳۰} برای نواحی پیشنهادی بهینه‌سازی شده‌اند تا با اندازه و شکل کوچک علائم راهنمایی سازگاری بیشتری داشته باشند. فرآیند شامل شناسایی نواحی مرتبط توسط شبکه پیشنهاد منطقه، استخراج ویژگی‌ها با شبکه عصبی کانولوشنی و طبقه‌بندی نهایی علائم به کلاس‌های مختلف است.

در الگوریتم بهبودیافته تشخیص علائم راهنمایی بر اساس Faster R-CNN، استفاده از کانولوشن‌های

²⁴Data Augmentation

²⁵Random Forest (RF)

²⁶Linear Discriminant Analysis (LDA)

²⁷Histogram of Oriented Gradients (HOG)

²⁸Faster Region-Based Convolutional Neural Network (Faster R-CNN)

²⁹Region Proposal Network (RPN)

³⁰Anchor Boxes

تغییرپذیر^{۳۱} و هرم ویژگی‌ها^{۳۲} [۱۷] از نکات برجسته است. کانولوشن‌های تغییرپذیر به دلیل انعطاف‌پذیری بالا در مواجهه با تغییرات شکل و مقیاس علائم، فرآیند استخراج ویژگی‌ها را بهبود می‌دهند. هرم ویژگی نیز با ترکیب اطلاعات از لایه‌های مختلف شبکه، امکان استخراج ویژگی‌های دقیق‌تر و سطح بالا از علائم کوچک و پیچیده را فراهم می‌کند.

در پژوهش دیگری [۱۸] از نسخه بهینه‌شده ResNet50-D برای استخراج ویژگی‌های قوی‌تر استفاده شده است. همچنین، ماژول توجه به هرم ویژگی‌ها اضافه شده است تا تمرکز بیشتری روی نواحی مهم مانند علائم جاده‌ای ایجاد شود. این ماژول توجه، نواحی پیشنهادی تولیدشده را تقویت کرده و به طبقه‌بندی‌کننده ارسال می‌کند که دقت سیستم را در محیط‌های شلوغ و پیچیده جاده‌ای افزایش می‌دهد.

نتایج این مطالعات نشان داده‌اند که با استفاده از بهبودهایی مانند کانولوشن‌های تغییرپذیر، ماژول‌های توجه و بهینه‌سازی جعبه‌های لنگر می‌توان Faster R-CNN را برای کاربردهای خاص مانند تشخیص علائم راهنمایی بهینه کرد. این بهبودها باعث افزایش مقاومت مدل در برابر تغییرات محیطی و ارائه نتایج سریع‌تر و دقیق‌تر می‌شوند. مدل YOLO^{۳۳} [۱۹]، که در سال ۲۰۱۶ توسط جوزف ردمن و همکاران معرفی شد، تحولی اساسی در حوزه شناسایی اشیاء ایجاد کرد و به‌ویژه در تشخیص علائم راهنمایی و رانندگی کاربردهای چشمگیری داشت. برخلاف روش‌های سنتی نظیر R-CNN و Faster R-CNN که فرآیند شناسایی را در دو مرحله جداگانه انجام می‌دادند، YOLO توانست این مراحل را در یک گام یکپارچه کند. این تغییر، سرعت و کارایی مدل را به شکل چشمگیری افزایش داد. نسخه اولیه این مدل^{۳۴} [۱۹] با تأکید بر سرعت، امکان شناسایی بلادرنگ اشیاء را فراهم کرد، اما محدودیت‌هایی در شناسایی اشیاء کوچک داشت. نسخه‌های بعدی مانند YOLOv2 و YOLOv3 با بهبود معماری شبکه و تقویت قابلیت تشخیص اشیاء در مقیاس‌های مختلف، این نقاط ضعف را کاهش دادند. YOLOv3 با ارائه تعادلی مناسب بین دقت و سرعت، به‌عنوان پایه‌ای برای توسعه نسخه‌های پیشرفته‌تر از جمله YOLOv4، YOLOv5، و YOLOv7 شناخته شد.

کاربرد YOLO در تشخیص علائم راهنمایی و رانندگی با توسعه نسخه‌های جدید گسترش یافت. در یکی از تحقیقات جدید، مدل YOLOv7 در مقاله‌ای به نام YOLO-CCA توسط جیانگ و همکاران (۲۰۲۴) [۲۰] برای شناسایی علائم راهنمایی مورد استفاده قرار گرفت. این مدل با افزودن ماژول‌هایی برای تقویت ویژگی‌های

^{۳۱}Deformable Convolutions^{۳۲}Feature Pyramid Network (FPN)^{۳۳}You Only Look Once^{۳۴}YOLOv1

جزئی و جمع‌آوری اطلاعات کلی، توانست دقت تشخیص علائم پیچیده را بهبود بخشد و عملکرد بهتری در شرایط متغیر محیطی ارائه دهد. این تحقیق با استفاده از مجموعه داده‌های واقعی شامل تصاویری از علائم در شرایط مختلف، مانند تغییرات نور و زاویه دید، انجام شد.

در مقاله دیگری با عنوان YOLO-TS که توسط چن و همکاران در سال ۲۰۲۴ معرفی شد [۲۱]، بهینه‌سازی میدان‌های دریافت و حذف انکرها^{۳۵} به منظور افزایش دقت و سرعت تشخیص علائم انجام شد. در این پژوهش از مجموعه داده‌های ترکیبی مانند GTSRB و سایر مجموعه‌های مشابه استفاده شده است. این تغییرات با کاهش وابستگی به انکرهای دستی، انعطاف‌پذیری بیشتری برای شناسایی علائم در محیط‌های پویا ایجاد کردند.

تحقیقات دیگری نیز بر بهبود معماری YOLO متمرکز بوده‌اند. در مقاله Improved YOLOv5 که توسط وانگ و همکاران در سال ۲۰۲۱ منتشر شد [۲۲]، تغییراتی نظیر افزودن هرم ویژگی توجهی^{۳۶} و ماژول تقویت ویژگی‌ها به YOLOv5 اعمال گردید. این تغییرات توانایی مدل را در شناسایی علائم کوچک و پیچیده بهبود بخشید و دقت آن را در شرایط محیطی متغیر افزایش داد. این پژوهش از مجموعه داده علائم راهنمایی و رانندگی LISA^{۳۷} [۲۳]، که شامل تصاویر علائم راهنمایی آمریکایی با شرایط متنوع محیطی است، بهره برد.

مقاله دیگری به نام Sign-YOLO نیز، که از YOLOv7 استفاده کرده است [۲۴]، با بهره‌گیری از مکانیزم توجه توانست دقت شناسایی علائم پیچیده را به شکل چشمگیری افزایش دهد. مدل TRD-YOLO که توسط MDPI Sensors در سال ۲۰۲۳ معرفی شد، به‌طور ویژه برای شناسایی علائم کوچک طراحی شده است. این مدل با استفاده از ماژول استخراج ویژگی جهانی و سر تشخیص سبک، عملکرد فوق‌العاده‌ای در این زمینه ارائه داد. مجموعه داده Sign Traffic (Small STS)، Dataset که به‌طور خاص برای علائم کوچک طراحی شده بود، به‌عنوان پایه داده این تحقیق مورد استفاده قرار گرفت.

نسخه‌های مختلف YOLO مانند YOLOv3 و نسخه‌های جدیدتر نظیر YOLOv8 نیز تأثیر شایانی در پیشرفت تشخیص علائم راهنمایی و رانندگی داشته‌اند. YOLOv3 با پایداری بالا، توانایی شناسایی علائم رایج در کشورهای اروپایی را با استفاده از مجموعه داده GTSRB فراهم کرد، در حالی که YOLOv8 با بهبود قابل توجه در دقت و سرعت، برای شناسایی علائم پیچیده‌تر مورد استفاده قرار گرفت. این نسخه‌ها با ارائه قابلیت‌هایی مانند حذف انکرها، تقویت ویژگی‌ها، و استفاده از مکانیزم‌های توجه، به ابزارهایی بسیار کارآمد برای شناسایی بلادرنگ علائم راهنمایی و رانندگی تبدیل شده‌اند و نقش مهمی در توسعه سیستم‌های هوشمند رانندگی و بهبود

³⁵ Anchor-Free Detection

³⁶ Attention Feature Pyramid

³⁷ Laboratory for Intelligent and Safe Automobiles (LISA)

ایمنی جاده‌ای ایفا کرده‌اند.

۴.۲ مدل‌های ترنسفورمر

مدل‌های ترنسفورمر، که در سال ۲۰۱۷ معرفی شدند [۲۵]، با استفاده از مکانیسم خودتوجهی^{۳۸} [۲۵] و توانایی پردازش هم‌زمان داده‌ها، انقلابی در یادگیری عمیق ایجاد کردند. این مدل‌ها ابتدا در حوزه پردازش زبان طبیعی مورد استفاده قرار گرفتند، اما به سرعت توانستند به حوزه‌های بینایی کامپیوتر هم گسترش یابند. معرفی ترنسفورمرهای بینایی^{۳۹} [۲۶] در سال ۲۰۲۰ نشان داد که این رویکرد می‌تواند در وظایف پیچیده بینایی نیز عملکرد بی‌نظیری داشته باشد. در ترنسفورمرهای بینایی، تصاویر به قطعات کوچکی تقسیم می‌شوند که هر قطعه به عنوان یک توکن جداگانه پردازش می‌شود. این توکن‌ها سپس با مکانیسم خودتوجهی بررسی می‌شوند تا ارتباطات میان بخش‌های مختلف تصویر تحلیل شود. این ساختار به مدل اجازه می‌دهد تا به طور هم‌زمان جزئیات دقیق و ویژگی‌های کلی تصویر را تحلیل کند و در وظایف مختلف بینایی، بهبود چشمگیری در دقت و کارایی ایجاد نماید.

یکی از مهم‌ترین پیشرفت‌ها در استفاده از ترنسفورمرها، توسعه مدل‌های شناسایی اشیاء مانند DETR^{۴۰} [۲۷] بود که به عنوان جایگزینی برای روش‌های سنتی مبتنی بر CNN معرفی شد. مدل DETR با حذف فرآیندهای چندمرحله‌ای مانند تولید نواحی پیشنهادی و استفاده مستقیم از خودتوجهی، توانست دقت بالایی را در شناسایی اشیاء با مقیاس‌های مختلف ارائه دهد. این ویژگی، به ویژه در زمینه شناسایی علائم راهنمایی و رانندگی، کاربرد قابل توجهی داشته است. مدل‌های ترنسفورمرهای بینایی و DETR با توانایی خود در تحلیل روابط پیچیده میان عناصر تصویر، عملکرد بهتری در شناسایی علائم کوچک، علائم با شرایط نوری متفاوت و علائم پیچیده از خود نشان داده‌اند.

در پژوهش‌های اخیر، استفاده از ترنسفورمرهای بینایی و مدل‌های مبتنی بر ترنسفورمر در شناسایی علائم راهنمایی و رانندگی به نتایج درخشانی منجر شده است. به عنوان مثال، در [۲۸] با استفاده از مجموعه داده‌های آلمان و بلژیک^{۴۱} [۲۹]، مدل توانست عملکردی بسیار دقیق در شناسایی علائم به نمایش بگذارد. همچنین،

³⁸Self-Attention Mechanism

³⁹Vision Transformers (ViT)

⁴⁰Deformable Transformer (DETR)

⁴¹Belgium Traffic Sign Dataset (BelgiumTS)

مدل ترنسفورمر بینایی محلی^{۴۲} [۳۰] که ترکیبی از شبکه‌های عصبی کانولوشنی و ترنسفورمرها است و توسط فرزین پور و همکاران معرفی شده، با استفاده از ماژول محلی سازی توانسته است دقت ۸.۹۹٪ را در مجموعه داده راهنمایی و رانندگی ایران [۳۱] و ۶۶.۹۹٪ را در مجموعه داده آلمان به دست آورد. این مدل با کاهش پیچیدگی محاسباتی و تمرکز بیشتر بر نواحی مرتبط با علائم، کارایی قابل توجهی از خود نشان داده است.

از سوی دیگر، مقاله [۳۲] با استفاده از نسخه‌ای بهبودیافته از DETR، شامل ماژول‌های پولینگ هرمی فضایی گسترش‌یافته^{۴۳} [۳۳] و ماژول تجمیع باقی‌مانده ویژگی‌ها^{۴۴} [۳۴] توانسته است عملکردی استثنایی در شناسایی علائم با مقیاس‌های مختلف ارائه دهد. این تحقیق با استفاده از مجموعه داده‌های آلمان و چین، دقت بالایی را در شناسایی علائم کوچک و بزرگ گزارش کرده است. همچنین در مقاله دیگری [۳۵]، نسخه‌ای سبک‌تر از RT-DETR معرفی شده که با کاهش پیچیدگی محاسباتی، توانسته است شناسایی بلادرنگ علائم راهنمایی را بهبود بخشد. این مدل بر روی مجموعه داده آلمان آزمایش شده و عملکرد قابل توجهی را از نظر سرعت و دقت ارائه داده است.

یکی از ترکیب‌های نوآورانه، استفاده از مدل‌های ترنسفورمر بینایی کارآمد^{۴۵} [۳۶] همراه با YOLOv5 در پژوهشی بود که توانست از سرعت بالای YOLOv5 و دقت بالای ترنسفورمرها به‌طور هم‌زمان بهره‌مند شود. این ترکیب بر روی مجموعه داده آلمانی آزمایش شده و نتایج درخشانی در شناسایی علائم راهنمایی و رانندگی نشان داده است. این پیشرفت‌ها، به‌ویژه با استفاده از مجموعه داده‌های استاندارد نظیر آلمان، بلژیک، ایران، و چین، توانسته‌اند عملکرد مدل‌ها را در شرایط متنوع محیطی شامل تغییرات نوری، زوایای مختلف و مقیاس‌های متفاوت، بهبود دهند. مدل‌های ترنسفورمر با دقت بالا و انعطاف‌پذیری خود، ابزار کلیدی برای توسعه سیستم‌های هوشمند رانندگی و ارتقای ایمنی جاده‌ها هستند و به‌عنوان یکی از پایه‌های اصلی فناوری‌های نوین بینایی کامپیوتر شناخته می‌شوند.

⁴²Local Vision Transformer (LVT)

⁴³Dilated Spatial Pyramid Pooling (DSPP)

⁴⁴Feature Residual Aggregation Module (FRAM)

⁴⁵Efficient Vision Transformers

۵.۲ منابع

1. , P. (2021). "Intelligent Transportation Systems: From Good Practices to Standards." CRC Press, Boca Raton, FL, USA.
2. Piccioli, A., et al. (1996). "Identification of candidate regions using specific colors and classification using pattern matching."
3. Zadeh, A., Kasvand, B. (1998). "Geometric transformations for enhancing system robustness against scale and rotation changes."
4. Ellmeyer, W., Zwahlen, (1994). "The first papers that applied neural networks for sign recognition."
5. Escalera, S., Others. (2003). "A hybrid method combining genetic algorithms for detection and neural networks for classification."
6. Bahlmann, C., Zhu, Y., Ramesh, V., Pellkofer, M., and Koehler, T. (2005). "A system for traffic sign detection, tracking, and recognition using color, shape, and motion information." In Proceedings of the IEEE Intelligent Vehicles Symposium, pages 255–260. IEEE Press.
7. Gao, X. W., Podladchikova, L., Shaposhnikov, D., Hong, K., and Shevtsova, N. (2006). "Recognition of traffic signs based on their colour and shape features extracted using human vision models." Journal of Visual Communication and Image Representation, 17(4):675–685.
8. Maldonado Bascon, S., et al. (2010). "Optimization on pictogram identification for road-sign recognition task using SVMs." Computer Vision and Image Understanding.

9. Hu, et al. (2010). "Local feature-based approach and Bag-of-Words model for sign recognition."
10. Stallkamp, J., Schlipsing, M., Salmen, J., Igel, C. (2011). "Man vs. Computer: Benchmarking Machine Learning Algorithms for Traffic Sign Recognition." 2011 IEEE International Joint Conference on Neural Networks (IJCNN), 3009–3016.
11. Sermanet, P., LeCun, Y. (2011). "Traffic Sign Recognition with Multi-Scale Convolutional Networks." In Proceedings of the International Joint Conference on Neural Networks (IJCNN), pp. 2809–2813.
12. Ciresan, D. C., Meier, U., Masci, J., Gambardella, L. M., Schmidhuber, J. (2012). "Multi-column deep neural networks for traffic sign classification." Neural Networks, 32, 333–338.
13. Breiman, L. (2001). "Random Forests." Machine Learning, 45(1), 5–32.
14. Fisher, R. A. (1936). "The use of multiple measurements in taxonomic problems." Annals of Eugenics, 7(2), 179–188.
15. Dalal, N., Triggs, B. (2005). "Histograms of Oriented Gradients for Human Detection." In Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR), 886–893.
16. Ren, S., He, K., Girshick, R., Sun, J. (2015). "Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks." Advances in Neural Information Processing Systems (NeurIPS), 28, 91–99.
17. Zhu, H., Li, D. (2020). "Traffic sign detection using Faster R-CNN with FPN and deformable convolutions."

18. Li, X., Xie, Z., Deng, X., Wu, Y., Pi, Y. (2021). "Traffic sign detection based on improved faster R-CNN for autonomous driving." *The Journal of Supercomputing*, 78(2), 1458–1480.
19. Redmon, J., Divvala, S., Girshick, R., Farhadi, A. (2016). "You Only Look Once: Unified, Real-Time Object Detection." *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 779–788.
20. Jiang, L., Zhan, P., Bai, T., Yu, H. (2024). "YOLO-CCA: A Context-Based Approach for Traffic Sign Detection."
21. Chen, J., Huang, H., Zhang, R., Lyu, N., Guo, Y., Dai, H.-N., Yan, H. (2024). "YOLO-TS: Real-Time Traffic Sign Detection with Enhanced Accuracy Using Optimized Receptive Fields and Anchor-Free Fusion."
22. Wang, J., Chen, Y., Gao, M., Dong, Z. (2021). "Improved YOLOv5 network for real-time multi-scale traffic sign detection."
23. LISA: Laboratory for Intelligent and Safe Automobiles. "LISA Traffic Sign Dataset."
24. Chu, J., Zhang, C., Yan, M., Zhang, H., Ge, T. (2023). "TRD-YOLO: A Real-Time, High-Performance Small Traffic Sign Detection Algorithm." *Sensors*, 23(8), 3871.
25. Vaswani, A., et al. (2017). "Attention Is All You Need." *Advances in Neural Information Processing Systems*.
26. Dosovitskiy, A., et al. (2020). "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale."
27. Carion, N., et al. (2020). "End-to-End Object Detection with Transformers." In *European Conference on Computer Vision*.

28. Mingwin, S., et al. (2024). "Revolutionizing Traffic Sign Recognition: Unveiling the Potential of Vision Transformers."
29. Belgium Traffic Sign Dataset (BelgiumTS).
30. Farzinpour, M., Rahmani, H., Ebrahimi, M. (2023). "Local Vision Transformer: Efficient Integration of CNN and Transformer for Traffic Sign Recognition." IEEE Transactions on Intelligent Transportation.
31. Persian Traffic Sign Dataset.
32. Xia, J., et al. (2023). "DSRA-DETR: An Improved DETR for Multiscale Traffic Sign Detection." Sustainability, 15(14), 10862.
33. Dilated Spatial Pyramid Pooling (DSPP).
34. Feature Residual Aggregation Module (FRAM).
35. RT-DETR: Traffic Sign Detection Based on Lightweight Real-Time DETR.
36. Efficient Vision Transformers for Traffic Sign Recognition.

فصل ۳

روش‌ها

۱.۳ مقدمه

پیش‌پردازش داده‌ها یکی از مراحل اصلی در فرآیند تحلیل و آماده‌سازی داده‌ها است که به منظور بهبود کیفیت داده‌ها و فراهم کردن اطلاعات مناسب برای استفاده در مدل‌سازی و تحلیل انجام می‌شود. داده‌های خام معمولاً شامل اطلاعات ناقص، نویز یا ویژگی‌های نامتناسب هستند که می‌توانند بر کیفیت تحلیل و نتایج تأثیر منفی بگذارند. در این فصل، مراحل پیش‌پردازش داده‌های مربوط به پروژه شناسایی علائم راهنمایی و رانندگی توضیح داده خواهد شد.

۲.۳ تغییر اندازه و نرمال‌سازی تصاویر

در پیش‌پردازش داده‌ها، تغییر اندازه و نرمال‌سازی تصاویر دو مرحله اساسی برای هماهنگی و بهینه‌سازی داده‌های ورودی هستند. تصاویر خام در دیتاست اغلب ابعاد و مقیاس‌های متفاوتی دارند که می‌تواند پردازش آن‌ها را دشوار کرده و منجر به نتایج غیر دقیق شود. برای حل این مسئله، ابتدا تصاویر به ابعاد ثابت $(N \times N)$ تغییر اندازه داده می‌شوند و سپس مقادیر پیکسل‌ها نرمال‌سازی می‌شوند تا مدل بتواند به طور بهینه‌تری یادگیری را انجام دهد.

فرآیند تغییر اندازه تصاویر به این صورت است که تمامی تصاویر ورودی به ابعاد ثابت $(N \times N)$ بازنمونه‌گیری می‌شوند. این بازنمونه‌گیری با استفاده از روش‌هایی مانند بایلاینر^۱ یا نزدیک‌ترین همسایه^۲ انجام می‌شود. فرمول ریاضی تغییر اندازه برای نگاشت تصویر I با ابعاد اولیه $(H \times W)$ به تصویر I' با ابعاد $(N \times N)$ به صورت زیر است:

$$I'(x', y') = I\left(x \cdot \frac{H}{N}, y \cdot \frac{W}{N}\right)$$

که در آن:

• $I'(x', y')$: مقدار پیکسل در تصویر تغییر اندازه داده شده

• $I(x, y)$: مقدار پیکسل در تصویر اصلی

• H, W : ارتفاع و عرض تصویر اولیه

• N : ابعاد جدید تصویر

در مرحله نرمال‌سازی، مقادیر پیکسل‌ها که معمولاً در بازه $[0, 255]$ قرار دارند، به بازه $[0, 1]$ نگاشت می‌شوند:

$$p' = \frac{p}{255}$$

که در آن:

• p : مقدار اصلی پیکسل

• p' : مقدار نرمال‌شده پیکسل

برگشت‌پذیری نرمال‌سازی نیز با معادله زیر انجام می‌شود:

$$I_{\text{original}} = (I_{\text{normalized}} \times \sigma) + \mu$$

^۱Bilinear
^۲Neighbor Nearest

کاربردهای برگشت‌پذیری شامل نمایش یا ذخیره تصاویر به شکل اولیه و انجام تحلیل‌های اضافی بر تصاویر اصلی است.

برای هر تصویر I_{original} که شامل سه کانال رنگی (قرمز، سبز، آبی) است، نرمال‌سازی به صورت زیر انجام

می‌شود:

$$I_{\text{normalized}} = \frac{I_{\text{original}} - \mu}{\sigma}$$

که در آن:

• $I_{\text{normalized}}$: مقدار پیکسل در تصویر نرمال‌شده

• I_{original} : مقدار اصلی پیکسل در تصویر

• μ : میانگین مقادیر پیکسل برای هر کانال رنگی

• σ : انحراف معیار مقادیر پیکسل برای هر کانال رنگی

این نرمال‌سازی باعث کاهش تأثیر ویژگی‌های با مقیاس بزرگ‌تر شده و همگرایی مدل را تسریع می‌کند. ترکیب این دو مرحله (تغییر اندازه و نرمال‌سازی) به مدل کمک می‌کند تا داده‌های ورودی را به شکلی استاندارد و بهینه پردازش کند.

۳.۳

بهبود بینایی ماشین با ادغام درک معنایی، استدلال شناختی و روان‌فیزیک

سیستم‌های بینایی ماشین در دهه‌های اخیر با تحولات شگرفی روبه‌رو شده‌اند؛ به نحوی که از روش‌های ساده شناسایی اشیاء و تشخیص الگو فراتر رفته و به الگوریتم‌هایی دست یافته‌اند که قادرند مفاهیم پیچیده‌تری را درک کرده و درباره آن‌ها استدلال نمایند. با این حال، در محیط‌های واقعی که پویا، ناهمگن و غیرقابل پیش‌بینی هستند، مدل‌های سنتی مبتنی بر استخراج ویژگی‌های خام یا الگوهای صرفاً آماری، با محدودیت مواجه می‌شوند. ترکیب درک معنایی، استدلال شناختی و روان‌فیزیک در یک چارچوب واحد، امکان ساخت سیستم‌های هوشمند و مقاوم‌تری را فراهم می‌سازد که نه تنها قادر به شناسایی اشیاء هستند، بلکه معنای آن‌ها را در بستر کاربردی و انسانی درک کرده، روابطشان را تحلیل نموده و واکنش‌های مناسبی از خود نشان می‌دهند. این رویکرد جامع همچنین توانایی سیستم‌های بینایی را در تعمیم دانش به موقعیت‌های جدید و تصمیم‌گیری در شرایط بحرانی یا ناآشنا بهبود می‌بخشد.

درک معنایی: از طبقه‌بندی ساده به تحلیل زمینه‌ای عمیق

درک معنایی، توانایی سیستم برای فرارفتن از سطح پیکسل‌ها و ویژگی‌های محاسباتی اولیه، و ورود به حوزه معناداری اشیاء و صحنه است. برخلاف رویکردهای سنتی که تمرکزشان بر شناسایی برچسب اشیاء در سطحی ایستا بود، درک معنایی سعی می‌کند ساختار و بافت صحنه، همچنین عملکرد و جایگاه اشیاء را در محیط بررسی کند. این موضوع به‌ویژه در سامانه‌های خودران، رباتیک پیشرفته، و حوزه‌هایی مانند نظارت تصویری اهمیت می‌یابد، زیرا تعامل میان اشیاء، اهداف، و رفتارها می‌تواند تأثیر عمیقی بر نتیجه نهایی داشته باشد. برای نمونه، تشخیص یک عابر پیاده در کنار خیابان به تنهایی کافی نیست؛ سیستم باید بفهمد که عابر احتمالاً قصد عبور دارد و به دلیل نزدیک بودن به خط عابر، باید سرعت خودرو کاهش یابد یا دستورات هشدار فعال شوند.

تولید گراف صحنه

تولید گراف صحنه، یکی از روش‌های کلیدی در رسیدن به درک معنایی عمیق است. در این گراف، هر شیء به‌عنوان یک گره نمایش داده می‌شود و کنش‌ها یا روابط میان اشیاء مختلف از طریق یال‌ها مشخص می‌شوند. برای

نمونه، در یک صحنه شهری می‌توان شینی به نام «خودرو» را شناسایی کرد و رابطه «در حال حرکت به سمت» را میان آن و «تابلوی ایست» قرار داد. علاوه بر این، یک «عابر پیاده» نیز می‌تواند در رابطه «نزدیک» با همین تابلو قرار گرفته باشد. این مدل‌سازی ساختارمند به سامانه اجازه می‌دهد فراتر از حضور صرف اشیاء رفته و تصمیمات یا پیش‌بینی‌های خود را بر پایه روابط و بافت عمومی صحنه بنا کند.

هستان‌شناسی‌های سلسله‌مراتبی

به‌جای آنکه هر شیء در طبقه‌بندی‌های مجزا و بدون ارتباط با یکدیگر تعریف شود، هستان‌شناسی‌های سلسله‌مراتبی تلاش دارند ساختاری لایه‌لایه از مفاهیم را ارائه دهند. به این ترتیب، اشیاء در رده‌بندی‌هایی از کلان به خرد تقسیم‌بندی می‌شوند و ویژگی‌های مشترک در سطوح بالاتر به اشتراک گذاشته می‌شود. برای مثال، مفهوم «خودرو» می‌تواند زیرمجموعه‌ای از «وسیله نقلیه» باشد که خود در سطح بالاتری به «وسیله حمل و نقل» متصل است. چنین رویکردی کمک می‌کند سیستم در صورت مواجهه با اشیاء جدید یا دسته‌بندی‌های ناشناخته، از روابط سلسله‌مراتبی برای تشخیص سریع‌تر و درک عمیق‌تر استفاده کند. این شیوه همچنین زمانی که داده‌های آموزشی محدود هستند، کارآمدتر خواهد بود؛ زیرا دانش به‌دست‌آمده از اشیاء یک رده می‌تواند برای شناسایی رده دیگری به‌کار گرفته شود.

مدل‌های ترکیب تصویر و زبان

در کنار روش‌های مبتنی بر گراف و هستان‌شناسی، مدل‌هایی که از ترکیب اطلاعات زبانی و تصویری بهره می‌برند نیز نقش بسزایی در افزایش درک معنایی ایفا کرده‌اند. این مدل‌ها تلاش می‌کنند بین متن و تصویر ارتباط برقرار نمایند و به این ترتیب، اشیاء یا صحنه‌ها را نه فقط به صورت بصری، بلکه در چارچوب توصیف‌های زبانی هم تحلیل کنند. چنین رویکردی برای کاربردهایی مانند جستجوی تصویری متنی، زیرنویس‌گذاری خودکار تصاویر و ویدئوها، و حتی پاسخگویی به پرسش‌های متنی بر پایه تصاویر بسیار سودمند است. هم‌افزایی دانش زبانی با ویژگی‌های تصویری، زمینه را برای درکی گسترده‌تر از بافت و عملکرد عناصر صحنه فراهم می‌کند.

استدلال شناختی: تمرکز بر نقش عملکردی اشیاء

همان‌طور که درک معنایی ساختار و روابط اشیاء در صحنه را ترسیم می‌کند، استدلال شناختی به بررسی نقش و عملکرد هر یک از این اشیاء می‌پردازد. در واقع، استدلال شناختی به سامانه اجازه می‌دهد تا فراسوی حضور و دسته‌بندی ظاهری اشیاء حرکت کند و نحوه تعامل و کارکرد آن‌ها را بسنجد. برای مثال، اگر در صحنه‌ای یک «نردبان» دیده می‌شود، تنها تشخیص آن به عنوان «نردبان» کافی نیست؛ سامانه باید قابلیت تشخیص این نکته را داشته باشد که وجود نردبان شاید نشانه کار تعمیراتی باشد و حضور افراد در نزدیکی آن محتمل‌تر است. این سطح از استدلال شناختی بسیار فراتر از طبقه‌بندی ساده رفته و نیازمند مدل‌سازی احتمالاتی یا منطقی برای «چگونه» و «چرا»ی وجود اشیاء و افراد است.

ترکیب استدلال شناختی با درک معنایی برای کاربردهایی مانند ربات‌های خدمت‌رسان در محیط‌های خانگی نیز ضروری است. ربات باید بتواند تشخیص دهد که یک «لیوان» معمولاً در کجاها قرار دارد، چه افرادی ممکن است از آن استفاده کنند و با چه اهدافی. این نوع از آگاهی عملکردی موجب می‌شود تعامل ربات با انسان‌ها یا اشیاء پیرامون خود، طبیعی‌تر و کارآمدتر باشد.

روان‌فیزیک: همسویی ادراک ماشین با انسان

روان‌فیزیک به بررسی ارتباط میان ویژگی‌های فیزیکی محرک‌ها و پاسخ‌های حسی و ادراکی انسان می‌پردازد. برای نمونه، بررسی اینکه تا چه حد تغییر در کنتراست یا شدت روشنایی می‌تواند ادراک بصری انسان را مختل کند یا نوع توجه بصری را تغییر دهد، در این حوزه مطرح است. بهره‌گیری از اصول روان‌فیزیک در سیستم‌های بینایی ماشین به این معنا است که الگوریتم‌ها و معماری‌ها طوری طراحی شوند که تا حد ممکن نزدیک به شیوه ادراک انسان عمل کنند. این رویکرد تنها برای تقلید کارکرد مغز انسان نیست؛ بلکه هدف اصلی، رسیدن به سامانه‌های مقاومی است که بتوانند در شرایط نور کم، نویز بالا یا تضادهای رنگی شدید، همچنان به خوبی عمل کنند.

از منظر پیاده‌سازی، برخی از الگوریتم‌ها و مدل‌های بینایی ماشین سعی دارند با تعریف توابع هزینه یا معیارهای ارزیابی که بر پایه حساسیت بینایی انسان شکل گرفته‌اند، نتایج نهایی را در راستای درک انسانی هدایت کنند. برای نمونه، استفاده از معیارهایی که به کیفیت ادراکی تصویر اهمیت می‌دهند، می‌تواند مفیدتر از معیارهای صرفاً پیکسلی باشد.

ترکیب و ادغام این سه حوزه — درک معنایی، استدلال شناختی و روان‌فیزیک — باعث شکل‌گیری سیستم‌های بصری پیشرفته‌تری می‌شود که علاوه بر آنکه قادرند اشیاء را درکی سطحی و زودگذر نکنند، بلکه معنای آن‌ها را در یک زمینه وسیع‌تری ببینند، استدلال‌های مبتنی بر نقش و کارکرد اشیاء را به‌کار گیرند و در نهایت، با حساسیت‌های ادراکی انسان سازگاری بیشتری داشته باشند. این رویکرد جامع می‌تواند پایه‌گذار نسل جدیدی از سامانه‌های هوشمند باشد که در عرصه‌هایی چون حمل‌ونقل، رباتیک، مراقبت‌های بهداشتی و حتی هنر و سرگرمی، کارایی و پایداری بالاتری داشته باشند.

۴.۳ ارزیابی تأثیر شرایط آب‌وهوایی شبیه‌سازی شده بر عملکرد مدل

در اکثر مناطق جغرافیایی، شرایط جوی و آب و هوایی به‌طور مداوم تغییر می‌کند و می‌تواند تأثیرات زیادی بر عملکرد سیستم‌های بینایی ماشین داشته باشد. از جمله عواملی که می‌توانند دید سیستم‌های بینایی را مختل کنند، می‌توان به بارش باران، برف، مه، باد شدید و تابش شدید نور خورشید اشاره کرد. شبیه‌سازی این شرایط جوی به‌منظور ارزیابی و بهبود عملکرد مدل‌های بینایی در مواجهه با شرایط واقعی ضروری است. در این راستا، افکت‌هایی مانند باران، برف، مه، باد و نور خورشید به‌طور مستقل یا ترکیبی بر روی تصاویر اعمال می‌شوند که در ادامه به توضیح هر یک پرداخته می‌شود.

۵.۳ خلاصه‌ای بر مفاهیم پردازش تصویر

پردازش تصویر یکی از شاخه‌های مهم در علوم کامپیوتر است که به تحلیل و تغییر تصاویر دیجیتال می‌پردازد. یک تصویر دیجیتال معمولاً به‌صورت آرایه‌ای دوبعدی از پیکسل‌ها تعریف می‌شود که هر پیکسل نشانگر سطح روشنایی یا مقدار رنگ در نقطه‌ای خاص است. در تصاویر رنگی، هر پیکسل با ترکیبی از چند کانال رنگ (اغلب قرمز، سبز و آبی) مشخص می‌شود. شدت یا مقدار هر کانال بیانگر سهم آن کانال در تولید رنگ کلی پیکسل است. در نتیجه، هر تصویر رنگی را می‌توان آرایه‌ای سه‌بعدی در نظر گرفت که بعد سوم آن به کانال‌های رنگ اختصاص دارد.

مهم‌ترین تغییراتی که در پردازش تصویر اعمال می‌شوند، شامل برش، تغییر اندازه، چرخش، وارونگی افقی

یا عمودی و تنظیم رنگ است. برش تصویر با هدف تمرکز بر بخش‌های مهم آن انجام می‌گیرد، در حالی که تغییر اندازه برای سازگاری ابعاد تصویر با نیازهای مختلف (مثلاً در ورودی مدل‌های یادگیری عمیق) صورت می‌پذیرد. اعمال چرخش و وارونگی برای افزایش تنوع داده و شبیه‌سازی زوایای مختلف دید به کار می‌روند. از سوی دیگر، تنظیم رنگ می‌تواند تغییراتی در روشنایی، کنتراست و اشباع رنگ تصویر ایجاد کند تا شرایط نوری گوناگون یا جلوه‌های بصری مختلف را بازنمایی نماید. در بخش‌های بعدی، افکت‌های ویژه‌ای همچون باران، برف، مه، باد و نور خورشید معرفی می‌شوند که بر اساس همین مفاهیم اصلی پردازش تصویر پیاده‌سازی شده‌اند.

۱.۵.۳ افکت باران (Rain)

برای شبیه‌سازی افکت باران، ابتدا تعداد قطرات باران بر اساس ابعاد تصویر و شدت بارش محاسبه می‌شود. این قطرات به‌طور تصادفی در تصویر قرار می‌گیرند و به‌وسیله خطوط عمودی با زاویه‌ای کمی مایل رسم می‌شوند. فرمول محاسبه تعداد قطرات باران به‌صورت زیر است:

$$N = \frac{\text{شدت} \times \text{ارتفاع} \times \text{عرض}}{300}$$

در این فرمول، N تعداد قطرات، عرض و ارتفاع ابعاد تصویر و شدت بارش به‌طور دلخواه است. قطرات باران به‌طور تصادفی در محدوده‌ای از زاویه حرکت $[80^\circ, 100^\circ]$ رسم می‌شوند.

۲.۵.۳ افکت برف (Snow)

برای ایجاد افکت برف، دانه‌های برف به‌صورت دایره‌هایی سفید در تصویر رسم می‌شوند. تعداد دانه‌های برف با توجه به ابعاد تصویر و چگالی برف محاسبه می‌شود. فرمول محاسبه تعداد دانه‌های برف به‌صورت زیر است:

$$N = \frac{\text{چگالی} \times \text{ارتفاع} \times \text{عرض}}{300}$$

برای هر دانه برف، شعاع آن به‌طور تصادفی از بازه $[1, 3]$ انتخاب می‌شود. دانه‌های برف با این شعاع‌های

تصادفی و موقعیت‌های تصادفی در تصویر اضافه می‌شوند.

۳.۵.۳ افکت مه (Fog)

افکت مه با افزودن یک لایه سفید به تصویر شبیه‌سازی می‌شود. ابتدا یک لایه سفید به اندازه تصویر ساخته می‌شود و سپس این لایه با تصویر اصلی ترکیب می‌شود تا نمای مه‌آلودی ایجاد گردد. چگالی مه با استفاده از یک پارامتر کنترل می‌شود. فرمول محاسبه تصویر مه به صورت زیر است:

$$\text{لایه مه} \times \text{چگالی} + \text{تصویر} \times (\text{چگالی} - 1) = \text{خروجی}$$

۴.۵.۳ افکت باد (Wind)

• افکت باد با استفاده از تاری حرکتی (Motion Blur) شبیه‌سازی می‌شود. برای شبیه‌سازی این افکت، یک هسته تاری افقی ساخته می‌شود که به وسیله آن حرکت باد در تصویر شبیه‌سازی می‌شود. اندازه هسته تاری به طور تصادفی از مقدار قدرت باد محاسبه می‌شود و فرمول محاسبه آن به صورت زیر است:

$$20 \times \text{قدرت باد} = \text{اندازه هسته تاری}$$

۵.۵.۳ افکت نور خورشید (Sunlight)

افکت نور خورشید به وسیله یک لایه رنگی گرم (معمولاً رنگ قرمز) شبیه‌سازی می‌شود. این لایه رنگی به تصویر اضافه می‌شود و شدت آن از طریق پارامتر شدت کنترل می‌شود. فرمول ترکیب لایه نور خورشید با تصویر اصلی به صورت زیر است:

$$\text{لایه نور خورشید} \times (\text{شدت نور}) + \text{تصویر} \times (1/0) = \text{خروجی}$$

۶.۵.۳ روش‌های اعمال فیلترها

برای اعمال این فیلترها بر روی مجموعه داده، می‌توان از دو روش اصلی استفاده کرد: اعمال فیلترها به صورت مستقل یا ترکیبی. در روش مستقل، هر افکت به طور جداگانه بر روی تصویر اعمال می‌شود و این کار می‌تواند به مدل کمک کند تا اثر هر فیلتر را به صورت بهینه بیاموزد. در روش ترکیبی، افکت‌ها به صورت همزمان بر روی تصویر اعمال می‌شوند که این روش نمایی واقع‌گرایانه‌تر ایجاد کرده و شرایط محیطی پیچیده‌تری را شبیه‌سازی می‌کند.

۷.۵.۳ تأثیر فیلترها بر مدل

اعمال فیلترهای محیطی بر روی مجموعه داده می‌تواند اثرات گوناگونی بر عملکرد مدل‌های بینایی داشته باشد. برای نمونه، آموزش مدل با داده‌هایی که افکت‌های محیطی شبیه‌سازی شده (باران، برف، مه و ...) دارند، ممکن است توانایی مدل را در شناسایی اشیاء تحت شرایط متنوع افزایش دهد. همچنین این اقدام می‌تواند پایداری مدل را در مواجهه با داده‌های واقعی که شرایط محیطی گوناگونی دارند، بهبود بخشد. با این حال، اگر مدل بیش از اندازه به داده‌های شبیه‌سازی شده وابسته شود، ممکن است در شرایط واقعی عملکرد ضعیفی از خود نشان دهد.

۸.۵.۳ درصد اعمال فیلترها

در هنگام اعمال افکت‌ها بر روی مجموعه داده، درصد داده‌هایی که تحت تأثیر این فیلترها قرار می‌گیرند، تأثیر چشمگیری بر عملکرد مدل دارد. اگر این درصد پایین باشد (10%-30%)، مدل می‌تواند ویژگی‌های اصلی داده‌ها را حفظ کند و در عین حال در شرایط گوناگون نیز کارایی مناسبی داشته باشد. با افزایش این درصد (30%-90%)، مدل می‌تواند شرایط پیچیده‌تری را شبیه‌سازی کرده و در نتیجه در محیط‌های واقعی مقاوم‌تر عمل کند. با این حال، اگر درصد افکت‌ها بیش از اندازه بالا رود، مدل ممکن است بیش از حد به شرایط شبیه‌سازی شده وابسته شده و در شرایط واقعی عملکرد مطلوبی نداشته باشد.

۶.۳ ضرورت افزایش داده‌ها و مدیریت عدم تعادل

داده‌های نامتعادل زمانی رخ می‌دهند که تعداد نمونه‌های موجود در برخی کلاس‌ها به مراتب بیشتر از کلاس‌های دیگر باشد. این مسئله باعث می‌شود مدل تمایل بیشتری به یادگیری کلاس‌های پرتعداد پیدا کند و در نتیجه عملکرد آن در تشخیص کلاس‌های کم‌نمونه کاهش یابد. علاوه بر این، داده‌های موجود ممکن است شرایط محیطی مختلف (مانند زوایای مختلف، نورپردازی متغیر یا نویز) را به خوبی پوشش ندهند و این موضوع می‌تواند باعث کاهش قابلیت تعمیم‌پذیری مدل شود.

۱.۶.۳ نسبت عدم تعادل و ارتباط آن با افزایش داده‌ها

در مسائل یادگیری ماشین با داده‌های نامتعادل، مدل‌ها تمایل دارند بیشتر روی کلاس‌های پرتعداد تمرکز کنند. برای اندازه‌گیری میزان عدم تعادل بین کلاس‌ها، از معیار نسبت عدم تعادل^۳ استفاده می‌شود:

$$IR = \frac{N_{\max}}{N_{\min}}$$

۲.۶.۳ فلوچارت الگوریتم SMOTE

این فلوچارت مراحل الگوریتم SMOTE را برای تولید نمونه‌های مصنوعی و مدیریت عدم تعادل داده‌ها نشان می‌دهد (شکل ۱.۳).

۳.۶.۳ فلوچارت وزن‌دهی در تابع هزینه

این فلوچارت فرآیند اختصاص وزن به کلاس‌ها در تابع هزینه را برای کاهش تأثیر داده‌های نامتعادل تشریح می‌کند (شکل ۲.۳).

^۳Ratio Imbalance

جدول ۱.۳: جدول مقایسه روش‌های افزایش داده‌ها و متوازن‌سازی


روش	نوع	هدف	مزایا	معایب
چرخش ۱	افزایش داده	شبیه‌سازی زوایای مختلف	ساده، سریع، افزایش تنوع داده‌ها	ممکن است ویژگی‌های اصلی در زوایای خاص حذف شوند
برش ۲	افزایش داده	تمرکز بر بخش‌های مختلف تصویر	افزایش تنوع و جزئیات	احتمال حذف اطلاعات مهم
وارونه‌سازی افقی ۳	افزایش داده	شبیه‌سازی دید مخالف	ساده، سریع	فقط در برخی مسائل کاربرد دارد
تغییر روشنایی و کنتراست ۴	افزایش داده	شبیه‌سازی شرایط نوری مختلف	مقاوم‌سازی در برابر نور	ممکن است منجر به داده‌های غیرواقعی شود
SMOTE ۵	متوازن‌سازی	تولید نمونه‌های مصنوعی برای کلاس‌های کم‌نمونه	حل مشکل عدم تعادل کلاس‌ها	ممکن است داده‌های نویزی تولید کند
وزن‌دهی در تابع هزینه ۶	متوازن‌سازی	افزایش توجه مدل به کلاس‌های کم‌نمونه	بدون تغییر داده‌ها، پیاده‌سازی آسان	نیاز به تنظیم دقیق وزن‌ها
VGANs	افزایش/متوازن‌سازی	تولید داده‌های واقعی و متوازن	تولید داده‌های بسیار واقعی	پیچیدگی بالا، نیاز به منابع محاسباتی زیاد

Rotation¹Cropping²Horizontal Flip³Brightness and Contrast Adjustment⁴Synthetic Minority Over-sampling Technique (SMOTE)⁵Class Weighting in the Loss Function⁶Generative Adversarial Networks (GANs)⁷

۷.۳ مروری بر روش‌های افزایش داده

در این بخش، چهار روش اصلی برای غنی‌سازی و متوازن‌سازی داده‌ها معرفی می‌گردد که در پروژه حاضر تأثیر قابل توجهی داشته‌اند. هر یک از این روش‌ها، به صورت مستقل یا در ترکیب با یکدیگر، می‌تواند در سامانه‌های مختلف (از محیط‌های آزمایشگاهی تا سیستم‌های تولیدی در مقیاس وسیع) مورد استفاده قرار گیرد.

- **چرخش تصادفی (Random Rotation):** با اعمال زوایای مختلف بر تصاویر ورودی، سامانه می‌تواند الگوهای چرخیده تابلوها را نیز تشخیص دهد. این روش، به ویژه در مواردی که تصاویر به شکل اتفاقی یا از دوربین‌هایی با زوایای غیرثابت ثبت می‌شوند، اثربخشی بالایی دارد. در سطح تولید، این فرایند اغلب قبل از ذخیره‌سازی تصاویر در دیتابیس یا هنگام آماده‌سازی batchها اعمال می‌شود تا مدل در طول




شکل ۱.۳: فلوچارت الگوریتم SMOTE

آموزش با تنوع زاویه مواجهه گردد.

- **تغییر روشنایی و کنتراست (Color Jitter):** شبیه‌سازی شرایط نوری مختلف (روز، شب، هوای ابری و غیره) کمک می‌کند مدل در سناریوهای واقعی قوی‌تر عمل کند. این روش در سامانه‌های هوشمند تشخیص علائم، خصوصاً برای دوربین‌هایی با نوردهی متغیر یا در محیط‌هایی با نور ناهمگن، بسیار مفید است. در مراکز پردازشی بزرگ (نظیر HPC یا خوشه‌های محاسباتی)، می‌توان این فرایند را به صورت توزیع شده اعمال کرد تا عملیات پیش‌پردازش سنگین پیش از مرحله آموزش انجام شود.

- **SMOTE در سطح ویژگی:** در مواردی که برخی کلاس‌ها (مانند نوع خاصی از علائم نادر) نمونه‌های بسیار کمی داشته باشند، مدل تمایل به نادیده گرفتن آن‌ها پیدا می‌کند. SMOTE با تولید نمونه‌های مصنوعی بر اساس همسایگی داده‌های واقعی در فضای ویژگی، تنوع داده را بالا می‌برد. این الگوریتم



شکل ۲.۳: فلوچارت وزن‌دهی در تابع هزینه

اغلب بعد از استخراج بردار ویژگی از شبکه‌های عمیق (مثلاً لایه‌های میانی CNN) اعمال می‌گردد تا نمونه‌های کم‌تعداد تقویت شوند. در سامانه‌های مقیاس بزرگ، اجرای SMOTE ممکن است به‌صورت دنباله‌ای (Pipeline) با سایر مراحل تحلیل داده ادغام شود.

- وزن‌دهی در تابع هزینه^۴: اگر توزیع کلاس‌ها بسیار نامتعادل باشد، اختصاص ضرایب وزنی بالاتر به کلاس‌های کم‌نمونه در حین آموزش (مثلاً از طریق تابع آنتروپی متقاطع^۵ وزندار) مانع از غلبه کلاس‌های پر تعداد می‌شود. این تکنیک در زیرساخت‌های تولیدی^۶ نیز کاربرد زیادی دارد؛ چراکه می‌توان بدون تغییر در داده‌ها، اهمیت برخی کلاس‌ها را بیشتر کرد و مدل را به سادگی بازآموزی^۷ نمود.

روش پیاده‌سازی و نکات اجرایی:

- در کتابخانه پای‌تورچ^۸، می‌توان با استفاده از ترکیب تبدیل‌ها^۹ مجموعه‌ای از تبدیلات مانند چرخش

^۴Weighted Loss

^۵CrossEntropyLoss

^۶Production

^۷Retrain

^۸PyTorch

^۹transforms.Compose

تصادفی^{۱۰} و تغییرات رنگ^{۱۱} را تعریف کرد. این فرایند اغلب در مرحله بارگذار داده‌ها^{۱۲} و پیش از ارسال داده به مدل انجام می‌شود تا همه عملیات لازم در حین بارگیری تصاویر صورت گیرد.

- برای بهره‌گیری از تکنیک نمونه‌برداری اقلیت مصنوعی^{۱۳} در فضای ویژگی، ابتدا داده‌ها را از طریق شبکه اولیه یا مدل از پیش آموزش دیده^{۱۴} عبور داده و خروجی لایه‌های میانی را استخراج می‌کنند. سپس الگوریتم SMOTE روی این بردارهای ویژگی اعمال می‌شود تا داده مصنوعی تولید گردد. در سیستم‌های بزرگ، این مرحله ممکن است در ریزخدمات^{۱۵} یا ماژول‌های جداگانه انجام پذیرد.

- در مورد وزن‌دهی در تابع هزینه^{۱۶}، تعیین وزن هر کلاس اغلب بر اساس معکوس فراوانی آن در مجموعه آموزشی انجام می‌شود. پیاده‌سازی عملی در پای‌تورچ معمولاً از طریق متد `nn.CrossEntropyLoss(weight=...)` صورت می‌گیرد. این روش بدون تغییر داده‌های خام، تأکید بیشتری بر کلاس‌های کم‌نمونه دارد و در مدل‌های مستقر در محیط تولید نیز به آسانی به‌روزرسانی می‌شود.

ترکیب این چهار روش — چرخش تصادفی^{۱۷}، تغییرات رنگ^{۱۸}، تکنیک نمونه‌برداری SMOTE و وزن‌دهی در تابع هزینه^{۱۹} — به افزایش تنوع داده و رفع مشکل عدم تعادل کمک می‌کند. نتیجه این امر، دستیابی به مدلی است که در محیط‌های واقعی و در مواجهه با موقعیت‌های متنوع، دقت و پایداری بیشتری از خود نشان می‌دهد.

۸.۳ معیارهای ارزیابی و مقایسه روش‌ها

پس از اینکه داده‌هایمان را روی مدل آموزش دادیم، نیاز به ارزش‌یابی مدل و روش‌های استفاده‌شده داریم. همچنین برای مقایسه روش‌های مختلف، معیارهای ارزیابی اهمیت بسیاری دارند. در این بخش، چند

¹⁰RandomRotation

¹¹ColorJitter

¹²DataLoader

¹³SMOTE (Synthetic Minority Oversampling Technique)

¹⁴Pretrained Model

¹⁵Microservices

¹⁶Weighted Loss

¹⁷RandomRotation

¹⁸ColorJitter

¹⁹Weighted Loss

مورد از معیارهای ارزیابی مدل‌ها همراه با معادل انگلیسی آن‌ها و فرمول‌ها معرفی و توضیح داده می‌شود.

دقت کلی^{۲۰} یکی از ابتدایی‌ترین معیارها برای سنجش عملکرد مدل است که نسبت پیش‌بینی‌های صحیح مدل را صرف نظر از نوع کلاس نشان می‌دهد. این معیار برای مجموعه داده‌هایی که تعداد نمونه‌های هر کلاس تقریباً برابر است و نسبت عدم‌توازن^{۲۱} نزدیک به 1 است، یک شاخص مناسب محسوب می‌شود. با این حال، برای داده‌هایی که کلاس‌های نادر دارند، دقت کلی ممکن است تصویر اشتباهی از عملکرد مدل ارائه دهد. فرمول محاسبه نسبت عدم‌توازن و دقت کلی به شکل زیر است:

$$\text{Imbalance Ratio} = \frac{\text{تعداد نمونه‌های بزرگ‌ترین کلاس}}{\text{تعداد نمونه‌های کوچک‌ترین کلاس}} \quad (۱.۳)$$

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (۲.۳)$$

دقت پیش‌بینی مثبت‌ها^{۲۲} شاخص دیگری است که تمرکز آن بر درصد نمونه‌هایی است که به درستی به‌عنوان مثبت پیش‌بینی شده‌اند. این معیار زمانی اهمیت پیدا می‌کند که پیش‌بینی اشتباه یک کلاس مثبت هزینه بالایی داشته باشد. به عنوان مثال، در شناسایی علائم راهنمایی و رانندگی، اشتباه در پیش‌بینی علائم ایست یا سرعت می‌تواند منجر به حوادث خطرناک یا جریمه راننده شود. فرمول محاسبه این معیار به صورت زیر است:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (۳.۳)$$

Accuracy^{۲۰}
Imbalance Ratio^{۲۱}
Precision^{۲۲}

نرخ بازخوانی^{۲۳} یا حساسیت، شاخصی است که توانایی مدل در شناسایی تمامی نمونه‌های مثبت واقعی را اندازه‌گیری می‌کند. این معیار در شناسایی علائم ترافیکی با اهمیت بالا، مانند علائم هشداردهنده یا محدودیت سرعت، بسیار کاربرد دارد. از دست دادن شناسایی این علائم، که به خطای منفی کاذب منجر می‌شود، می‌تواند اثرات جدی داشته باشد. فرمول محاسبه نرخ بازخوانی به شرح زیر است:

$$\text{Recall} = \frac{TP}{TP + FN} \quad (۴.۳)$$

امتیاز F1^{۲۴} به عنوان میانگین هارمونیک بین Precision و Recall تعریف می‌شود. این معیار به‌ویژه زمانی اهمیت پیدا می‌کند که داده‌ها نامتوازن باشند و نیاز به ارزیابی عملکرد مدل در شناسایی هر دو نوع خطای مثبت کاذب و منفی کاذب وجود داشته باشد. فرمول امتیاز F1 به شکل زیر است:

$$F1 =$$

$$2 \times \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (3.5)$$

نرخ مثبت کاذب^{۲۵} نشان می‌دهد که مدل چه تعداد از نمونه‌های منفی واقعی را به اشتباه به عنوان مثبت پیش‌بینی کرده است. از سوی دیگر، نرخ منفی کاذب^{۲۶} مشخص می‌کند که مدل چه تعداد از نمونه‌های مثبت واقعی را نتوانسته شناسایی کند. فرمول این معیارها به صورت زیر تعریف می‌شوند:

$$\text{FPR} = \frac{FP}{FP + TN} \quad (۶.۳)$$

Recall^{۲۳}F1 Score^{۲۴}False Positive Rate^{۲۵}False Negative Rate^{۲۶}

$$FNR = \frac{FN}{FN + TP} \quad (۷.۳)$$

منحنی ROC^{۲۷} ارتباط بین Recall و نرخ مثبت کاذب^{۲۸} را نمایش می‌دهد. مساحت زیر این منحنی^{۲۹} توانایی کلی مدل در تفکیک بین کلاس‌های مختلف را نشان می‌دهد. این معیار برای مدل‌هایی که احتمالات پیش‌بینی می‌کنند، مانند شبکه‌های عمیق، کاربرد ویژه‌ای دارد. فرمول محاسبه مساحت زیر منحنی ROC به شرح زیر است:

$$AUC = \int_0^1 ROC(x) dx \quad (۸.۳)$$

در کنار این معیارها، ماتریس سردرگمی^{۳۰} ابزاری گرافیکی است که عملکرد مدل را با تقسیم پیش‌بینی‌ها به چهار دسته نشان می‌دهد:

		Predicted	
		Positive	Negative
Actual	Positive	True positive	False negative
	Negative	False positive	True negative

شکل ۳.۳: ماتریس سردرگمی برای مدل مورد بررسی

این ماتریس برای تحلیل نقاط ضعف مدل و شناسایی کلاس‌هایی که بیشتر با یکدیگر اشتباه گرفته می‌شوند، بسیار مفید است.

^{۲۷} Receiver Operating Characteristic
^{۲۸} False Positive Rate (FPR)
^{۲۹} Area Under Curve (AUC)
^{۳۰} Confusion Matrix

در مقایسه مدل‌ها، معمولاً از ترکیبی از این معیارها استفاده می‌شود تا نقاط قوت و ضعف هر مدل به طور کامل مشخص گردد. به عنوان مثال:

- مدل‌های سنتی مبتنی بر ویژگی‌های رنگ و شکل ممکن است در معیارهایی نظیر Specificity عملکرد بهتری داشته باشند.

- مدل‌های یادگیری عمیق مانند شبکه‌های CNN^{۳۱} یا مدل‌های مبتنی بر Transformer^{۳۲} معمولاً در معیارهایی نظیر AUC-ROC و Recall برجسته‌تر هستند.

مدل‌ها section


۱.۸.۳ MobileNetV2

مدل MobileNetV2 یک شبکه عصبی کانولوشنی است که برای پردازش تصاویر طراحی شده است و به‌ویژه برای دستگاه‌های موبایل و سیستم‌های با منابع محدود بهینه‌سازی شده است. این مدل از تکنیک‌های نوینی مانند Residuals Inverted و Bottlenecks Linear بهره می‌برد که موجب کاهش پیچیدگی محاسباتی و افزایش کارایی در مقایسه با سایر مدل‌های مشابه می‌شود. از دیگر ویژگی‌های مهم این مدل، ساختار لایه‌های کانولوشنی به صورت Convolution Separable Depthwise است که در آن عملیات کانولوشن به دو بخش تقسیم می‌شود: کانولوشن عمقی و کانولوشن نقطه‌ای. این رویکرد باعث می‌شود که تعداد پارامترها به شدت کاهش یابد و در نتیجه، سرعت پردازش مدل افزایش یابد.

در مدل MobileNetV2، به جای استفاده از کانولوشن‌های سنتی، از یک ساختار جدید به نام Inverted Residuals استفاده می‌شود که در آن ابتدا یک لایه عریض با تعداد فیلتر بیشتر به وجود می‌آید و سپس با استفاده از Bottleneck Linear به طور مؤثری ابعاد ویژگی کاهش می‌یابد. این رویکرد باعث می‌شود که مدل بتواند ویژگی‌های پیچیده‌تری را در لایه‌های اولیه استخراج کند و در عین حال از لحاظ محاسباتی بهینه باشد.

Convolutional Neural Networks^{۳۱}
Transformer-based Models^{۳۲}

این مدل، برای بسیاری از کاربردهای بینایی کامپیوتری مانند شناسایی اشیاء، طبقه‌بندی تصاویر و تشخیص ویژگی‌ها در موبایل‌ها و دستگاه‌های کم‌قدرت به‌طور مؤثری مورد استفاده قرار می‌گیرد.



شکل ۴.۳: معماری شبکه عصبی MobileNetV2


۲.۸.۳ EfficientNet

مدل EfficientNet یکی از مدل‌های جدید و پیشرفته شبکه‌های عصبی است که توسط تیم Google AI در سال ۲۰۱۹ معرفی شد. این مدل به‌طور قابل توجهی نسبت به مدل‌های مشابه مانند ResNet و MobileNet بهینه‌تر است و برای بهبود کارایی شبکه‌های عصبی از یک رویکرد به نام Compound Scaling استفاده می‌کند. به عبارت دیگر، در این مدل علاوه بر افزایش عمق شبکه، مقیاس‌های دیگر مانند عرض شبکه و وضوح تصویر نیز به‌طور هم‌زمان افزایش می‌یابد تا کارایی بالاتری برای پردازش تصاویر به‌دست آید.

یکی از ویژگی‌های برجسته این مدل، کاهش Overhead در محاسبات و حافظه است. به‌طور معمول، افزایش عمق شبکه موجب افزایش میزان محاسبات و حافظه مصرفی می‌شود، اما با استفاده از رویکرد Compound Scaling در EfficientNet، به‌طور هم‌زمان ابعاد دیگر (عرض و وضوح) به‌صورت هوشمندانه‌ای افزایش می‌یابد تا مدل بهینه‌تر و با دقت بالاتری عمل کند.

این مدل نه تنها تعداد پارامترها را کاهش داده، بلکه دقت بیشتری در انجام وظایف بینایی کامپیوتری ارائه می‌دهد. EfficientNet به‌ویژه برای کار در محیط‌های با محدودیت منابع بسیار مناسب است و در

بسیاری از کاربردهای پیشرفته، مانند تشخیص تصاویر در پزشکی و شناسایی اشیاء، موفقیت‌های بزرگی داشته است.




شکل ۵.۳: معماری EfficientNet

۳.۸.۳ ResNet

مدل ResNet (Residual Networks) یکی از موفق‌ترین و پرکاربردترین مدل‌های شبکه عصبی است که در سال ۲۰۱۵ توسط Kaiming He و همکارانش معرفی شد. این مدل به‌ویژه برای شبکه‌های عمیق طراحی شده و از Residual Learning برای حل مشکل ناپدید شدن گرادیان در شبکه‌های عصبی عمیق بهره می‌برد. یکی از مشکلات اصلی در شبکه‌های عصبی عمیق، Vanishing Gradient Problem است که باعث می‌شود آموزش شبکه‌های با عمق زیاد بسیار دشوار و زمان‌بر شود. برای مقابله با این مشکل، ResNet از Skip Connections یا Residual Blocks استفاده می‌کند که به شبکه این امکان را می‌دهد تا مسیرهای کوتاه‌تری برای جریان گرادیان‌ها داشته باشد، در نتیجه، شبکه می‌تواند به‌طور مؤثری و بدون مشکل ناپدید شدن گرادیان، آموزش ببیند.

در مدل ResNet، از یک یا چند بلوک Residual استفاده می‌شود که در آن ورودی هر لایه به خروجی لایه‌ی بعدی اضافه می‌شود. این روش باعث می‌شود که شبکه به راحتی به عمق‌های بیشتر گسترش یابد بدون آنکه مشکلات یادگیری ایجاد شود. این مدل در سال‌های اخیر در بسیاری از رقابت‌ها و کاربردهای بینایی کامپیوتری به موفقیت‌های زیادی دست یافته است.



شکل ۶.۳: معماری ResNet

۴.۸.۳ ساختار معماری و اجزای اصلی

در یک نگاه کلی، ساختار مدل‌های ذکرشده را می‌توان به دو بخش اصلی تقسیم کرد:

۱. **بخش کانولوشنی (Convolutional Part):** شبکه‌های کانولوشنی با لایه‌های مختلف فیلترهایی

در ابعاد گوناگون، به دنبال شناسایی ویژگی‌های موضعی در سطح فرکانس-زمان (یا هر فضای ویژگی دیگر) هستند. خروجی این بخش، معمولاً یک نگاشت ویژگی^{۳۳} چندکاناله است که در هر مقطع زمانی، اطلاعات فشرده‌ای از الگوهای محلی^{۳۴} را ذخیره می‌کند.

۲. **بخش تمام‌اتصال (Fully Connected Part):** پس از استخراج ویژگی‌های موضعی، معمولاً

شبکه‌های عصبی به لایه‌های تمام‌اتصال یا fully connected متصل می‌شوند تا ویژگی‌های استخراج‌شده را برای تصمیم‌گیری‌های نهایی پردازش کنند. در مدل‌هایی مانند ResNet و MobileNetV2، این لایه‌ها اغلب با استفاده از کلاس‌های خروجی و توابع فعال‌سازی مانند Softmax برای طبقه‌بندی تصاویر استفاده می‌شوند.

^{۳۳}Feature Map

^{۳۴}Local Patterns

۵.۸.۳ مکانیزم آموزش و روش‌های ارزیابی

برای آموزش این مدل‌ها، ابتدا یک تابع هزینه مناسب تعریف می‌شود و سپس وزن‌های شبکه با استفاده از روش‌های بهینه‌سازی گرادیان محور نظیر Adam^{۳۵} یا SGD^{۳۶} به‌روزرسانی می‌گردند. بسته به این‌که مسئله از نوع طبقه‌بندی یا رگرسیون باشد، می‌توان از توابعی مانند آنتروپی متقاطع (Cross-Entropy) یا MSE^{۳۷} بهره برد. همچنین، برای جلوگیری از بیش‌برازش، روش‌هایی نظیر دراپ‌آوت^{۳۸}، توقف زودهنگام^{۳۹} و تنبیه وزن^{۴۰} متداول هستند.

در مرحله ارزیابی مدل، معیارهای موفقیت به نوع مسئله وابسته است:

- در سناریوهای طبقه‌بندی (مانند تشخیص اشیاء)، معیارهایی نظیر دقت^{۴۱}، امتیاز F1^{۴۲}، Precision^{۴۳} و Recall^{۴۴} کاربرد دارند.

- در وظایف پیش‌بینی یا بازتولید سیگنال، معیارهایی نظیر RMSE^{۴۵}، MAE^{۴۶} یا ضریب تعیین^{۴۷} R² ارزیابی مدل با این شاخص‌ها، میزان بهبود مدل ترکیبی را در مقایسه با روش‌های دیگر - یا در مقایسه با بهره‌گیری جداگانه از CNN و RNN - روشن‌تر می‌کند.

³⁵ Adaptive Moment Estimation

³⁶ Stochastic Gradient Descent

³⁷ Mean Squared Error

³⁸ Dropout

³⁹ Early Stopping

⁴⁰ Weight Decay

⁴¹ Accuracy

⁴² F1-Score

⁴³ Precision

⁴⁴ Recall

⁴⁵ Root Mean Squared Error

⁴⁶ Mean Absolute Error

⁴⁷ Coefficient of Determination

فصل ۴

نتایج

۱.۴ معرفی مجموعه داده

۱.۱.۴ ضرورت انتخاب دیتاست مناسب

انتخاب دیتاست مناسب یکی از حیاتی‌ترین مراحل است. این انتخاب مستقیماً بر دقت و موفقیت مدل‌های یادگیری ماشین تأثیر می‌گذارد. یک دیتاست ایده‌آل باید از تنوع بالایی در شرایط محیطی برخوردار باشد؛ به عنوان مثال، شرایطی مانند نورپردازی، زاویه دید و وضوح تصاویر باید به گونه‌ای متنوع باشند که مدل بتواند عملکردی قابل قبول در محیط‌های واقعی داشته باشد.

جامعیت و تعداد نمونه‌های کافی برای هر کلاس از علائم راهنمایی و رانندگی نیز از اهمیت بالایی برخوردار است. این ویژگی به مدل امکان می‌دهد تا انواع مختلف علائم را به درستی یاد بگیرد و دقت خود را در پیش‌بینی بهبود بخشد. علاوه بر این، ساختار استاندارد دیتاست و انوتیشن‌های دقیق نظیر جعبه‌های محصور^۱ یا ماسک‌های تفکیکی^۲ می‌توانند فرآیند آموزش و ارزیابی را تسهیل کنند. پذیرش گسترده دیتاست در جامعه علمی نیز به عنوان یک شاخص کیفیت و اعتبار، انتخاب آن را برای تحقیقات تسهیل می‌کند.

¹Bounding Boxes

²Segmentation Masks

تعادل کلاس‌ها و پوشش جغرافیایی گسترده دیتاست نقش مهمی در جلوگیری از تعصب مدل به کلاس‌های پرتعداد ایفا می‌کنند. در نهایت، دسترسی آزاد و مجوزهای مناسب استفاده از دیتاست، امکان بهره‌برداری در پروژه‌های آتی را فراهم می‌کند.

۲.۴ بررسی و تحلیل دیتاست‌ها

در ادامه، به بررسی و تحلیل چندین دیتاست معتبر در حوزه شناسایی علائم راهنمایی و رانندگی می‌پردازیم. هر یک از این دیتاست‌ها دارای ویژگی‌ها و کاربردهای خاص خود هستند که آن‌ها را برای پروژه‌های مختلف مناسب می‌سازد.

دیتاست **GTSRB**^۳ یکی از پرکاربردترین مجموعه داده‌ها در این زمینه است که شامل 50,000 تصویر از 43 کلاس مختلف علائم می‌باشد. تنوع بالای این دیتاست در شرایط نوری و زاویه دید به مدل‌ها امکان می‌دهد تا با تغییرات محیطی مختلف سازگار شوند و دقت بالایی در شناسایی علائم داشته باشند. کیفیت بالای انوتیشن‌های این دیتاست، که شامل جعبه‌های محصور است، فرآیند آموزش مدل‌ها را تسهیل کرده و دقت شناسایی را افزایش می‌دهد.

دیتاست **TT100K**^۴ با بیش از 100,000 تصویر و 100 کلاس مختلف، یکی از بزرگترین دیتاست‌ها در این حوزه محسوب می‌شود. این دیتاست به دلیل تنوع بالای شرایط محیطی و تعداد زیاد نمونه‌ها برای پروژه‌هایی که نیاز به داده‌های گسترده دارند بسیار مناسب است. با این حال، تمرکز جغرافیایی این دیتاست بر روی کشور چین می‌تواند در تعمیم مدل به سایر مناطق چالش‌هایی ایجاد کند و ممکن است باعث کاهش دقت مدل‌ها در شناسایی علائم راهنمایی و رانندگی در مناطق دیگر شود.

دیتاست **LISA**^۵ شامل حدود 25,000 تصویر از 47 کلاس مختلف علائم است. این دیتاست به دلیل تعادل نسبی بین کلاس‌ها و کیفیت مناسب تصاویر، برای پروژه‌هایی که بر روی علائم در محیط‌های کنترل‌شده تمرکز دارند، بسیار مناسب است. انوتیشن‌های دقیق این دیتاست، فرآیند آموزش مدل‌ها را بهبود بخشیده و دقت شناسایی را افزایش می‌دهد.

^۳German Traffic Sign Recognition Benchmark

^۴Traffic Sign Dataset 100K

^۵Laboratory for Intelligent and Safe Automobiles

دیتاست **Mapillary** با داشتن بیش از 100,000 تصویر و 600 کلاس مختلف، تنوع جغرافیایی و محیطی بسیار بالایی ارائه می‌دهد. این دیتاست برای پروژه‌های بین‌المللی و مطالعاتی که نیاز به داده‌های گسترده و متنوع دارند، گزینه‌ای ایده‌آل است. انوتیشن‌های دقیق و جامع این دیتاست، امکان آموزش مدل‌های پیچیده‌تر و دقیق‌تر را فراهم می‌آورد.

دیتاست **BelgiumTS**^۶ شامل حدود 7,000 تصویر از 108 کلاس مختلف علائم است. اگرچه کیفیت تصویری بالایی دارد، اما به دلیل محدودیت در تعداد نمونه‌ها و تنوع محیطی کمتر، برای پروژه‌هایی که نیاز به تنوع و داده‌های گسترده دارند، مناسب نیست. این دیتاست بیشتر برای پروژه‌های کوچک‌تر و تحقیقات مقدماتی کاربرد دارد.

علاوه بر دیتاست‌های فوق، تکنولوژی‌های نوینی مانند ترنسفورمرهای بینایی^۷ و روش‌های ترکیبی بین شبکه‌های عصبی کانولوشنی و ترنسفورمرها نیازمند دیتاست‌هایی با ساختار مناسب و ویژگی‌های دقیق هستند. دیتاست‌هایی که توانسته‌اند نیازهای این مدل‌های پیشرفته را برآورده کنند، نقش مهمی در پیشرفت تحقیقات و بهبود عملکرد سیستم‌های شناسایی علائم راهنمایی و رانندگی ایفا می‌کنند. به عنوان مثال، دیتاست‌های با انوتیشن‌های دقیق و تنوع بالا، امکان استفاده بهینه از مدل‌های ترنسفورمر را فراهم می‌آورند و باعث افزایش دقت و سرعت شناسایی می‌شوند.

Dataset	#Images	#Classes	#Signs	Attributes	Region	BBoxes	Unique
MTSD (TRAIN+VAL)	41,907	313	*206,388	occluded, exterior,	world-wide	✓	✓
MTSD	100,000	313	325,172	out-of-frame, dummy, ambiguous, included	world-wide	✓	×
TT100K ⁸	†100,000	221	26,349	—	China	✓	✓
MVD ⁹	20,000	†2	174,541	—	world-wide	✓	✓
GTSD ¹⁰	900	43	852	—	Germany	✓	×
RTSD ¹¹	†179,138	156	†104,358	—	Russia	✓	×
STS ¹²	3,777	20	5,582	—	Sweden	✓	×
LISA ¹³	6,610	47	7,855	—	USA	✓	×
GTSRB ¹⁴	—	43	39,210	—	Germany	×	×
BelgiumTS ¹⁵	—	108	8,851	—	Belgium	×	×

جدول ۱. بررسی اجمالی دیتاست‌های علائم راهنمایی و رانندگی.


جدول ۱. بررسی اجمالی دیتاست‌های علائم راهنمایی و رانندگی. این جدول مقایسه‌ای

دقیق از چندین دیتاست معتبر شناسایی علائم راهنمایی و رانندگی را ارائه می‌دهد.

^۶Belgium Traffic Sign Dataset

^۷Vision Transformers

اعداد ذکر شده تنها شامل تصاویر و انوتیشن‌های عمومی و قابل دسترس هستند. ستون «منحصر به فرد» به دیتاست‌هایی اشاره دارد که در آن‌ها هر باکس علائم راهنمایی فقط یک نمونه منحصر به فرد را نمایش می‌دهد و از تکرار یک علامت در تصاویر مختلف جلوگیری شده است. *۱۳۸,۶۶ علامت درون یک تاکسونومی خاص قرار دارند. †دیتاست TT100K تنها شامل ۱۰,۰۰۰ تصویر از علائم راهنمایی است. ||فقط ۴۵ کلاس از دیتاست TT100K بیش از ۱۰۰ نمونه دارند. ‡دیتاست MVD شامل تنها دو کلاس «پشت» و «جلو» است. †فریم‌های ویدیویی تنها ۱۵,۶۳۰ علامت منحصر به فرد را پوشش می‌دهند. §علامت‌های موجود در مجموعه انوتیشن‌های جزئی با علامت‌های مجموعه آموزش مطابقت دارند. هر دیتاست با توجه به ویژگی‌هایی مانند پوشش جغرافیایی، جعبه‌های محصور و استانداردهای انوتیشن برای مدل‌های یادگیری ماشین در شرایط واقعی ارزیابی شده است.



(ب) تصویر نمونه از دیتاست K100TT



(آ) تصویر نمونه از دیتاست GTSRB



(ج) تصویر نمونه از دیتاست LISA

شکل ۱.۴: تصاویر نمونه از دیتاست‌های مختلف شناسایی علائم راهنمایی و رانندگی

Author/Year	Model	Dataset	Accuracy (%)	Key Features
Kerim and Efe (2021)	ANN	GTSRB	95.0	Hybrid ANN with HOG, LBP
Li et al. (2022)	Color Histogram + PCA + HOG	GTSRB	99.99	Dimensionality reduction with PCA and improved HOG
Zaibi et al. (2021)	LeNet-5	GTSRB, BTSD	99.84 (GTSRB), 98.37 (BTSD)	Enhanced LeNet-5 with dropout, batch normalization
Bangquan and Xiong (2019)	Efficient CNN	GTSRB, LISA	98.6	Combines VGG16 and LeNet for efficiency
Vincent et al. (2020)	CNN	GTSRB, TT100K	98.44	Basic CNN with data augmentation
Mishra and Goyal (2022)	CNN	GTSRB, BTSC, Mapillary	99.76 (GTSRB), 99.79 (BTSC)	Uses advanced augmentation for robustness
Chu et al. (2023)	TRD-YOLO	TT100K, Mapillary	99.4 (TT100K), 98.5 (Mapillary)	Optimized YOLO for small traffic sign detection
Wang et al. (2021)	YOLOv5	TT100K, GTSRB	99.2 (TT100K), 98.9 (GTSRB)	Real-time multi-scale detection with YOLOv5
Mingwin et al. (2024)	Vision Transformer	GTSRB, BTSC, Mapillary	99.85 (GTSRB), 99.9 (BTSC)	Leveraged Vision Transformers for enhanced feature extraction

جدول ۲. مقایسه مدل‌ها و دیتاست‌های شناسایی علائم راهنمایی و رانندگی. این

جدول شامل مدل‌های مختلف، دیتاست‌های استفاده‌شده، دقت آن‌ها و ویژگی‌های کلیدی

برای مقایسه عملکرد و تکنیک‌های به‌کاررفته است.

۱.۲.۴ دلایل انتخاب و عدم انتخاب دیتاست‌ها

پس از بررسی و مقایسه دقیق دیتاست‌های مختلف، GTSRB به عنوان مناسب‌ترین گزینه برای این پروژه انتخاب شد. این دیتاست به دلیل جامعیت بالا، تنوع مناسب در شرایط محیطی و کیفیت استاندارد تصاویر، امکان آموزش مدل‌هایی با قابلیت تعمیم‌پذیری بالا را فراهم می‌کند. علاوه بر این، پذیرش گسترده GTSRB در جامعه علمی و دسترسی آزاد به آن، شرایط ایده‌آلی را برای مقایسه نتایج و استفاده عملی در تحقیقات ایجاد می‌کند.

سایر دیتاست‌ها، علی‌رغم داشتن ویژگی‌های مثبت، به دلیل محدودیت‌هایی مانند تمرکز جغرافیایی محدود، عدم تعادل در نمونه‌های کلاس‌ها، یا نیاز به منابع محاسباتی گسترده، برای اهداف این پروژه مناسب تشخیص داده نشدند. به عنوان مثال، TT100K به دلیل تمرکز بر یک منطقه خاص و تنوع محدود در برخی کلاس‌ها، گزینه ایده‌آلی برای تعمیم مدل نبود. LISA نیز با وجود طراحی مناسب برای محیط‌های کنترل‌شده، فاقد تنوع لازم برای استفاده در شرایط واقعی بود. همچنین، پیچیدگی انوتیشن‌ها در Mapillary

و تعداد محدود نمونه‌ها در BelgiumTS استفاده از این دیتاست‌ها را برای پروژه‌ای با نیاز به داده‌های متنوع و گسترده دشوار می‌کرد.



شکل ۲.۴: نمونه‌های موجود در هر کلاس در مجموعه داده ،

۳.۴ تحلیل ویژگی‌های آماری

علائم راهنمایی و رانندگی به‌گونه‌ای طراحی شده‌اند که برای انسان‌ها قابل فهم و سریعاً قابل تشخیص باشند. در این طراحی، از تأثیر شکل‌ها و رنگ‌های مختلف بر ادراک انسانی بهره گرفته شده است تا

پیام‌ها به ساده‌ترین و مؤثرترین شکل منتقل شوند. به عنوان مثال، رنگ قرمز که به طور طبیعی حس هشدار یا توقف را القا می‌کند، برای علائم ممنوعیت یا ایست استفاده می‌شود، و شکل مثلث که توجه را جلب می‌کند، برای علائم هشداردهنده به کار می‌رود.

در تحلیل آماری دیتاست علائم راهنمایی و رانندگی، دسته‌بندی داده‌ها نقش کلیدی در درک ساختار و ویژگی‌های آن دارد. این دیتاست شامل ۴۳ کلاس است که هر کدام نشان‌دهنده یک علامت خاص با معنا و کاربرد مشخص است. برای تحلیل جامع‌تر، داده‌ها را می‌توان از جنبه‌های مختلفی مانند معنایی، بصری و پیچیدگی دسته‌بندی کرد. هر یک از این دسته‌بندی‌ها دیدگاه متفاوتی را ارائه می‌دهد و به ما کمک می‌کند تا الگوها و ارتباطات پنهان در داده‌ها را کشف کنیم.

در این پروژه، ما با دسته‌بندی علائم بر اساس ویژگی‌های بصری مانند رنگ، شکل و پیچیدگی، و همچنین گروه‌بندی مفاهیم علائم به دسته زیردسته‌ها، تلاش می‌کنیم تا مدل را به درکی نزدیک به ادراک انسانی برسانیم. هدف این است که مدل نه تنها توانایی شناسایی و تشخیص علائم را داشته باشد، بلکه بتواند مفهوم آن‌ها را درک کرده و واکنشی مشابه رفتار انسان در مواجهه با این علائم نشان دهد. این رویکرد، پایه‌ای برای تحلیل دقیق‌تر توزیع داده‌ها و توسعه مدل‌هایی است که به طور طبیعی‌تر و مؤثرتر با محیط‌های واقعی تعامل داشته باشند. در ادامه، جزئیات هر دسته‌بندی و تأثیر آن بر عملکرد مدل مورد بررسی قرار خواهد گرفت.

۱.۳.۴ دسته‌بندی معنایی و بصری

علائم راهنمایی و رانندگی را طی یک فرآیند دو مرحله‌ای دسته‌بندی کردیم تا درک عمیق‌تری از معنای علائم و ویژگی‌های بصری آن‌ها به دست آوریم. در مرحله اول، علائم را بر اساس مفهوم و کاربریشان، بدون توجه به رنگ و شکل، گروه‌بندی کردیم. این مرحله با بهره‌گیری از تحلیل معنایی انجام شد تا معنا و نقش عملکردی علائم در مدیریت ترافیک بررسی شود. در مرحله دوم، علائم را با توجه به ویژگی‌های بصری مانند رنگ و شکل دسته‌بندی کردیم. در این بخش از اصول روان‌فیزیک استفاده کردیم تا نحوه ادراک علائم توسط انسان‌ها و ارتباط میان طراحی فیزیکی علائم و پیام آن‌ها را تحلیل کنیم. با ترکیب این دو رویکرد، مدلی طراحی کردیم که نه تنها توانایی شناسایی علائم را دارد، بلکه می‌تواند مفهوم و عملکرد

آن‌ها را نیز درک کند. این روش دوگانه، توانایی مدل در تصمیم‌گیری آگاهانه‌تر و شبیه‌تر به انسان را بهبود بخشید و گامی مهم در نزدیک‌تر کردن عملکرد هوش مصنوعی به ادراک انسانی بود.

دسته اصلی	زیردسته	تصاویر کلاس‌ها
علائم محدودیت سرعت	سرعت پایین	
	سرعت متوسط	
	سرعت بالا	
علائم ممنوعیت دیگر	محدودیت‌های وسیله نقلیه	
	ممنوعیت‌های عمومی	
	رفع محدودیت سرعت	
علائم رفع محدودیت	رفع محدودیت سبقت	
	علائم جهت‌دهی اولیه	
	علائم جهت‌دهی ثانویه	
علائم خطر	هشدارهای عمومی	
	خطرات هندسی جاده	
	شرایط سرعت و سطح جاده	
	خطرات ترافیک و عابر پیاده	
	خطرات محیطی	
	مناطق کار و ساخت‌وساز	
	علائم اولویت و توقف	
علائم خاص	علائم هشدار	
	ممنوعیت‌ها و محدودیت‌ها	

جدول ۲.۴: دسته‌بندی: دسته‌ها و زیردسته‌ها مفهوم و کاربرد خاص علائم را نشان می‌دهند. هر دسته به نوعی درجه اهمیت علائم را نیز مشخص می‌کند، مانند علائم هشداردهنده برای خطرات، محدودیت‌ها برای کنترل، و دستورات برای راهنمایی مستقیم. این ساختار به درک بهتر اولویت و معنای علائم کمک می‌کند.

رنگ	زیردسته	تصاویر کلاس‌ها
قرمز و سفید	محدودیت‌ها	
	ممنوعیت‌ها	
	هشدارها	
سیاه و سفید	رفع محدودیت‌ها	
	ممنوعیت‌ها	
زرد و سیاه	هشدارها	
زرد و سفید	هشدارها	
آبی و سفید	اطلاعاتی	

جدول ۳.۴: دسته‌بندی علائم براساس رنگ: نقش رنگ‌ها را در انتقال معنا و مفهوم علائم بوضوح قابل مشاهده است. هر رنگ با هدف خاصی طراحی شده است؛ مانند قرمز برای هشدار یا توقف، آبی برای دستورات، و زرد برای هشدارهای محیطی. این ارتباط میان رنگ و مفهوم، به درک سریع‌تر و تصمیم‌گیری بهتر کمک می‌کند.


شکل	زیردسته	تصاویر کلاس‌ها
دایره‌ای	محدودیت‌ها	
	ممنوعیت‌ها	
	اطلاعاتی	
مثلی	هشدارها	
لوزی	هشدارها	
مثث برعکس	حق تقدم	
شش ضلعی	توقف	

جدول ۴.۴: دسته‌بندی علائم بر اساس شکل: این دسته‌بندی تأثیر شکل‌ها در انتقال معنا و مفهوم علائم را نشان می‌دهد. برای مثال مثث برای هشدار، دایره برای محدودیت‌ها، و مربع برای اطلاعات عمومی. ترکیب شکل‌ها با رنگ‌ها معنای دقیق‌تری را منتقل می‌کند، مانند مثث قرمز برای هشدار خطر یا دایره آبی برای دستورات، که به شناسایی سریع‌تر و تصمیم‌گیری آگاهانه‌تر کمک می‌کند.


۲.۳.۴ تحلیل تنوع و عدم تعادل داده‌ها

حال برای بررسی میزان تنوع و پراکندگی داده‌ها، رویکرد‌های متفاوتی وجود خواهد داشت، در ساده‌ترین حالت می‌توان مجموعه داده را که متشکل از کلاس‌ها که هر کدام نشان‌دهنده یک علامت و معنا و مفهوم مستقل‌اند در نظر گرفت.

۱.۲.۳.۴ نمودار توزیع نمونه‌ها در کلاس‌ها



شکل ۳.۴: توزیع تعداد نمونه‌ها در کلاس‌ها (مرتب نشده) - این نمودار تعداد نمونه‌های موجود در هر کلاس را به ترتیب شماره کلاس‌ها (از ۰ تا ۴۲) نمایش می‌دهد.



شکل ۴.۴: توزیع تعداد نمونه‌ها در کلاس‌ها (مرتب شده بر اساس تعداد) - در این نمودار، کلاس‌ها بر اساس تعداد نمونه‌های موجود مرتب شده‌اند تا توزیع داده‌ها به شکل واضح‌تری قابل مشاهده باشد.

۲.۲.۳.۴ تحلیل عدم تعادل داده‌ها

اما همانطور که در بالا اشاره کردیم شیوه طراحی بصری علائم باعث شده که علائمی که شبیه هم هستند از لحاظ دسته بندی موضوعی هم بهم نزدیک تر باشند. پس می توانیم علائم را براساس معنا و جنس پیامی که انتقال می دهند که به نوعی هم میزان مهم بودن آن را نشان میدهد در زیر توزیع نمونه ها در دسته بندی های بصری و مفهومی که قبلا مطرح شد مشاهده می شود، توزیع نمونه‌ها در دسته‌بندی‌های مختلف از جمله رنگ، شکل، ترکیب شکل و رنگ و مفهوم علائم به وضوح نامتعادل است. این عدم توازن نشان‌دهنده فراوانی بسیار زیاد برخی دسته‌ها، مانند قرمز و سفید یا دایره، و فراوانی بسیار کم در دسته‌هایی مانند زرد و سفید با لوزی یا شش ضلعی است. چنین توزیعی می‌تواند مشکلات متعددی را ایجاد کند، از جمله سوگیری به سمت کلاس‌های پرتکرار، کاهش دقت در شناسایی کلاس‌های کم‌نمونه، و افت عملکرد مدل بر اساس معیارهای ارزیابی مانند Recall^{۱۶} و F1-Score^{۱۷}.

برای رفع این چالش‌ها، در این پژوهش مجموعه‌ای از تکنیک‌های افزایش داده و متوازن سازی به کار گرفته

^{۱۶}Recall

^{۱۷}F1-Score

شده است. یکی از این تکنیک‌ها چرخش تصادفی^{۱۸} است که با اعمال زوایای مختلف بر تصاویر ورودی، مدل را قادر می‌سازد الگوهای چرخیده را نیز شناسایی کند. این روش با افزایش تنوع در مجموعه داده، به بهبود تعمیم‌پذیری مدل کمک کرده است. علاوه بر این، تغییر روشنایی و کنتراست^{۱۹} برای شبیه‌سازی شرایط نوری مختلف، مانند نور روز، شب و شرایط با روشنایی متغیر، به کار گرفته شده است. این تکنیک، مدل را در برابر تغییرات نوری مقاوم‌تر ساخته و دقت آن را در سناریوهای متنوع افزایش داده است.

همچنین، از تکنیک SMOTE^{۲۰} برای تولید نمونه‌های مصنوعی در کلاس‌های کم‌نمونه استفاده شده است. این روش با افزایش تعداد نمونه‌های کلاس‌های نادر، توازن داده‌ها را بهبود بخشیده و شناسایی این کلاس‌ها را برای مدل تسهیل کرده است. علاوه بر این، وزن‌دهی در تابع هزینه^{۲۱} نیز برای کاهش تأثیر کلاس‌های پرتکرار مورد استفاده قرار گرفته است. این تکنیک با اختصاص وزن‌های بالاتر به کلاس‌های کم‌نمونه در حین آموزش، مدل را به طور ضمنی به شناسایی این کلاس‌ها ترغیب کرده و عملکرد آن را در پیش‌بینی کلاس‌های نادر ارتقا داده است.

ترکیب این روش‌ها به افزایش تنوع داده‌ها و بهبود توازن میان کلاس‌ها منجر شده است. نتایج حاصل نشان می‌دهد که این استراتژی‌ها توانسته‌اند بر مشکلات ناشی از نامتوازن بودن داده‌ها غلبه کرده و مدلی پایدارتر، قابل‌اعتمادتر و با توانایی تعمیم بالاتر در مواجهه با داده‌های واقعی ارائه دهند. این رویکرد در مسائل عملی، به ویژه در کاربردهایی که عدم توازن داده‌ها می‌تواند به عملکرد مدل آسیب برساند


¹⁸Random Rotation

¹⁹Color Jitter

²⁰Synthetic Minority Over-sampling Technique


²¹Weighted Loss

Sample Distribution by Categories, Subcategories, and Mixed Color-Shape Categories



شکل ۵.۴: این مجموعه نمودارها، توزیع نمونه‌ها را بر اساس رنگ، شکل، ترکیب شکل و رنگ و مفهوم علائم نمایش می‌دهد. نمودارها به وضوح نامتعادلی در توزیع داده‌ها را نشان می‌دهند؛ به طوری که برخی دسته‌ها مانند قرمز و سفید یا دایره بیشترین نمونه‌ها را دارند، در حالی که دسته‌هایی مانند زرد و سفید یا لوزی یا شش ضلعی به ندرت دیده می‌شوند.

Concept-Based Categories and Subcategories Distribution



شکل ۶.۴: نمودارها توزیع زیرکلاس‌های دسته‌بندی مفهومی را نمایش می‌دهند. نمودار بالا درصد نمونه‌های هر زیرکلاس را نسبت به کتگوری اصلی خود نشان می‌دهد، در حالی که نمودار پایین درصد نمونه‌های هر زیرکلاس را نسبت به کل دیتاست مقایسه می‌کند. این تحلیل به وضوح نامتوازن بودن برخی زیرکلاس‌ها را در هر دو مقیاس نشان می‌دهد،

۴.۴ متعادل سازی داده ها با استفاده از تکنیک های افزایش داده

برای رفع عدم توازن در توزیع کلاس ها، از روش های افزایش داده مانند SMOTE^{۲۲} استفاده شد. این روش با تولید نمونه های مصنوعی، داده های کلاس های اقلیت را افزایش داده و توزیع را متعادل می کند. علاوه بر آن، تکنیک های دیگری شامل چرخش^{۲۳}، تغییر نور و روشنایی^{۲۴}، جابجایی^{۲۵}، افزودن نویز^{۲۶} و تغییر مقیاس^{۲۷} به کار گرفته شدند.

این اقدامات منجر به بهبود توزیع کلاس ها و افزایش تنوع ویژگی ها شد. نتایج نشان داد که مدل پس از اعمال این روش ها دقت بیشتری در پیش بینی داده های اقلیت داشته و توانایی آن در مواجهه با شرایط مختلف افزایش یافته است. استفاده از این تکنیک ها به وضوح توانست عدم توازن داده ها را کاهش داده و کارایی مدل را بهبود بخشد.



(ب) نمونه ۲

(آ) نمونه ۱

شکل ۷.۴: نمونه هایی از تصاویر افزوده شده

همچنین، نمودار زیر توزیع کلاس ها را قبل و بعد از افزایش داده مقایسه می کند.

^{۲۲}Synthetic Minority Over-sampling Technique


^{۲۳}Rotation

^{۲۴}Brightness Adjustment

^{۲۵}Translation

^{۲۶}Adding Noise

^{۲۷}Scaling



شکل ۸.۴: توزیع کلاس‌ها قبل و بعد از افزایش داده

آمار	قبل از افزایش داده	بعد از افزایش داده
Max Image Count	2250	2250
Min Image Count	210	2250
Imbalance Ratio (Max / Min)	10.71	1.00
Average Image Count per Class	1036.58	2250.00
Standard Deviation of Image Count	790.44	0.00

جدول ۵.۴: ویژگی‌های آماری تصاویر قبل و بعد از افزایش داده در سطح کلاس

برای توازن داده‌ها از تکنیک‌هایی نظیر چرخش تصادفی، انتقال، وارونگی افقی و تکنیک‌های افزایش داده به طور مؤثری داده‌ها را متوازن کرده و نسبت عدم توازن را از 10.71 به 1.00 کاهش داده‌اند. این امر باعث می‌شود مدل آموزش دیده بر روی این داده‌ها کمتر به کلاس‌هایی با تعداد بیشتر تصاویر گرایش داشته باشد.

۱.۴.۴ متعادل سازی در سطح دسته بندی های معنایی و بصری

برای بهبود تعادل داده ها، فرآیند تعادل سازی نه تنها در سطح کلاس ها، بلکه در سطح دسته بندی های اصلی و زیر مجموعه های معنایی و بصری اعمال گردید.

جدول ۶.۴ تعداد تصاویر قبل و بعد از افزایش داده را بر اساس دسته بندی های اصلی شامل رنگ، شکل و مفهوم مقایسه می کند. این جدول نشان دهنده تغییرات در توزیع داده ها بین این دسته بندی ها است.

در ادامه، جدول ۷.۴ به صورت جزئی تر به بررسی نسبت های عدم تعادل در زیر گروه های مفهومی می پردازد و تغییرات پیش و پس از افزایش داده را برای این زیر گروه ها نشان می دهد. این مقایسه به وضوح میزان تأثیر فرآیند افزایش داده در متعادل سازی زیر گروه های مفهومی را مشخص می کند.

دسته بندی	قبل از افزوده سازی	بعد از افزوده سازی
دسته بندی های مبتنی بر رنگ		
زیر گروه قرمز و سفید	10.71	1.66
زیر گروه سیاه و سفید	1.75	1.02
زیر گروه زرد و سیاه	3.85	1.21
زیر گروه زرد و سفید	1.00	1.00
زیر گروه آبی و سفید	9.86	1.33
دسته بندی های مبتنی بر شکل		
زیر گروه دایره	10.71	1.96
زیر گروه مثلث	7.14	1.29
زیر گروه لوزی	1.00	1.00
زیر گروه مثلث وارونه	1.00	1.00
زیر گروه شش ضلعی	1.00	1.00
دسته بندی های مبتنی بر مفهوم		
زیر گروه علائم محدودیت سرعت	10.71	1.59
زیر گروه علائم بازدارنده دیگر	4.79	1.21
زیر گروه علائم رفع محدودیت	1.75	1.02
زیر گروه علائم اجباری	9.86	1.33
زیر گروه علائم خطر	7.14	1.29
زیر گروه علائم منحصر به فرد	2.77	1.25

جدول ۶.۴: جدول مقایسه ای نسبت عدم تعادل قبل و بعد از افزایش داده

گروه اصلی	زیرگروه	تعداد کل	بیشترین تعداد	کمترین تعداد	نسبت عدم تعادل (نهایی)
علائم محدودیت سرعت	سرعت کم	4680	2945	2220	1.32658
علائم محدودیت سرعت	سرعت متوسط	5250	1980	1410	1.40426
علائم محدودیت سرعت	سرعت زیاد	2850	1440	1410	1.02128
علائم بازدارنده دیگر	محدودیت وسیله نقلیه	3480	2010	1470	1.36735
علائم بازدارنده دیگر	ممنوعیت های عمومی	1050	630	420	1.5
علائم رفع محدودیت	رفع محدودیت سرعت	660	420	240	1.75
علائم رفع محدودیت	رفع محدودیت عبور	480	240	240	1
علائم اجباری	علائم جهت یابی اولیه	2309	1200	689	1.74165
علائم اجباری	علائم جهت یابی ثانویه	3330	2070	1680	1.23214
علائم خطر	هشدارهای عمومی	1650	1200	750	1.6
علائم خطر	خطرات هندسی جاده	1350	510	270	1.88889
علائم خطر	شرایط سرعت و سطح	660	390	270	1.44444
علائم خطر	خطرات عابران و ترافیکی	2880	1500	900	1.66667
علائم خطر	خطرات محیطی	2100	1320	780	1.69231
علائم خطر	مناطق ساخت و ساز	330	330	330	1
علائم منحصربه فرد	علائم اولویت و توقف	2940	2160	1379	1.56635
علائم منحصربه فرد	ممنوعیت ها و محدودیت ها	1110	1110	1110	1
علائم منحصربه فرد	علائم هشداردهنده	2100	2100	2100	1

جدول ۷.۴: نسبت های عدم تعادل قبل و بعد از افزوده سازی برای هر زیرگروه

۵.۴ پیش پردازش داده ها

در این بخش، فرآیند آماده سازی داده ها برای استفاده در مدل توضیح داده می شود. پیش پردازش داده ها مرحله ای کلیدی در طراحی و توسعه ی مدل های یادگیری عمیق^{۲۸} است و بهبود دقت و کارایی مدل به طور مستقیم به کیفیت این مرحله وابسته است. در این پروژه، فرآیند پیش پردازش شامل سه مرحله ی اصلی به شرح زیر است:

ابتدا تمامی تصاویر موجود در مجموعه داده به ابعاد ثابت 32×32 پیکسل تغییر اندازه داده شدند. تغییر اندازه^{۲۹} نه تنها سبب تسهیل پردازش داده ها توسط مدل می شود، بلکه باعث یکنواختی داده های ورودی^{۳۰} می گردد.

در مرحله ی دوم، مقادیر پیکسل های تصاویر به منظور بهبود فرآیند یادگیری به بازه ی $[0,1]$ نرمال سازی^{۳۱}

²⁸Deep Learning

²⁹Resizing

³⁰Input Data Uniformity

³¹Normalization

شدند. این نرمال‌سازی با تقسیم مقادیر پیکسل‌ها بر مقدار حداکثری ممکن (255) انجام شد. این عمل باعث شد داده‌ها از لحاظ مقیاس^{۳۲} در سطحی متناسب با نیازهای مدل قرار گیرند. به عنوان نکته‌ی قابل توجه، این عملیات معکوس‌پذیر است؛ یعنی با انجام معکوس نرمال‌سازی^{۳۳} (ضرب داده‌های نرمال‌شده در 255)، می‌توان تصویر اولیه را با دقت بالا بازسازی کرد. ۹.۴.



شکل ۹.۴: نمونه تصاویر قبل و بعد نرمال‌سازی. این تصاویر شامل نمونه‌هایی از تصاویر اصلی، تصاویر بعد از نرمال‌سازی و همچنین تصاویر بازسازی‌شده با استفاده از نرمال‌سازی معکوس هستند.

در این تحقیق، از سه مدل مختلف، EfficientNet و ResNet MobileNet برای ارزیابی عملکرد در پردازش تصاویر استفاده شده است. در مرحله‌ی سوم، تصاویر پیش‌پردازش‌شده به عنوان ورودی، به‌طور جداگانه بر روی هر یک از این مدل‌ها آزمایش شدند. مدل MobileNetV2 ۲ MobileNetV (Architecture) به دلیل طراحی سبک و توانایی بالا در یادگیری ویژگی‌ها در سیستم‌های کم‌منبع (Resource-

³²Scale

³³Inverse Normalization

(Constrained Systems) انتخاب شد. مدل ResNet (Residual Networks) به عنوان یک معماری عمیق با امکان اتصال مستقیم لایه‌ها (Residual Connections) برای یادگیری بهتر ویژگی‌های پیچیده مورد استفاده قرار گرفت. در نهایت، مدل EfficientNet (EfficientNet Architecture) به دلیل بهره‌وری بالا در استفاده از منابع محاسباتی و دقت بالا در مقایسه با مدل‌های مشابه، برای انجام آزمایشات در نظر گرفته شد. برای نمایش مراحل پیش‌پردازش، نمونه‌هایی از تصاویر اولیه، تصاویر پس از نرمال‌سازی، و همچنین تصاویر بازسازی شده با استفاده از نرمال‌سازی معکوس ارائه خواهند شد. این تصاویر در جدول زیر قرار داده شده‌اند و به صورت بصری تأثیر مراحل پیش‌پردازش و قابلیت بازسازی تصویر اولیه را نشان می‌دهند.

۶.۴ مقایسه عملکرد مدل‌ها

در این بخش، عملکرد سه مدل مختلف شامل ResNet، EfficientNet و MobileNet در شناسایی کلاس‌های مختلف با استفاده از داده‌های پیش‌پردازش شده و خام بررسی خواهد شد. هر مدل در دو حالت آموزش داده شده است: حالت اول با استفاده از داده‌های خام و حالت دوم با استفاده از داده‌های پیش‌پردازش شده. برای هر کدام از این شش حالت، نتایج به کمک معیارهای مختلف مانند دقت، فراخوانی و معیار F1 مقایسه خواهند شد. علاوه بر این، Confusion Matrices برای هر مدل و هر حالت نیز ارائه شده‌اند تا دیدگاه کاملی از عملکرد مدل‌ها در اختیار قرار گیرد.

۱.۶.۴ مقایسه معیارهای عملکرد مدل‌ها

F1 Score	Recall	Precision	Accuracy	Data Type	Model
0.709799	0.681077	0.866821	68.107680	Raw	MobileNetV2
0.961895	0.962866	0.967904	96.286619	Preprocessed	MobileNetV2
0.441328	0.346239	0.924542	34.623911	Raw	ResNet18
0.962967	0.963104	0.966514	96.310372	Preprocessed	ResNet18
0.328322	0.266825	0.656621	26.682502	Raw	EfficientNet
0.972184	0.974188	0.976981	97.418844	Preprocessed	EfficientNet

جدول ۸.۴: مقایسه عملکرد مدل‌های مختلف در داده‌های خام و پیش‌پردازش شده

در این جدول، مقایسه‌ای بین مدل‌های MobileNet، EfficientNet و ResNet در دو حالت داده (پیش‌پردازش شده و خام) از نظر دقت، فراخوانی و معیار F1 انجام شده است. همچنین، تفاوت میان معیار F1 هر مدل در حالت‌های مختلف نیز در جدول آورده شده است.


نتایج آزمون ANOVA نشان داد که تفاوت‌های مشاهده شده بین مدل‌ها در داده‌های خام و پیش‌پردازش شده از نظر آماری معنادار هستند (با $F\text{-statistic} = ۱۷/۷۷$ و $p\text{-value} = ۰/۰۱۳۵$). این نتایج حاکی از تأثیر مثبت پیش‌پردازش بر عملکرد مدل‌ها است. در عین حال، MobileNet در داده‌های خام عملکرد بهتری نسبت به مدل‌های دیگر داشت. این عملکرد بهتری می‌تواند به معماری سبک و کارآمد MobileNet مربوط باشد. این مدل از Depthwise Separable Convolutions برای کاهش پیچیدگی محاسباتی و افزایش کارایی استفاده می‌کند، که موجب می‌شود بتواند حتی در داده‌های خام و بدون پیش‌پردازش، ویژگی‌های عمومی تصاویر را به خوبی استخراج کند. همچنین، طراحی MobileNet به گونه‌ای است که نیاز به توان محاسباتی کمتری دارد و در مواجهه با داده‌های ساده‌تر یا کم‌حجم‌تر بهتر عمل می‌کند، در حالی که مدل‌های پیچیده‌تر مانند ResNet و EfficientNet به داده‌های پیش‌پردازش شده و پیچیده‌تری نیاز دارند تا عملکرد مطلوبی داشته باشند.

۲.۶.۴ ماتریس‌های اشتباه (Confusion Matrices)


در این بخش، Confusion Matrices برای هر مدل در دو حالت داده (پیش‌پردازش شده و خام) ارائه شده است. این ماتریس‌ها به طور دقیق نحوه عملکرد مدل‌ها را در پیش‌بینی کلاس‌ها نشان می‌دهند. شکل‌های زیر، Confusion Matrices مربوط به هر مدل را در هر دو حالت داده نشان می‌دهند.

فصل ۴: نتایج


سیستم بینایی وسایل نقلیه خودران برای شناسایی علائم راهنمایی و رانندگی




شکل ۱۱.۴: Data Preprocessed with MobileNet of Matrix Confusion




شکل ۱۰.۴: Data Raw with MobileNet of Matrix Confusion




شکل ۱۳.۴: Data Preprocessed with EfficientNet of Matrix Confusion



شکل ۱۲.۴: Data Raw with EfficientNet of Matrix Confusion



شکل ۱۵.۴: Data Preprocessed with ResNet of Matrix Confusion




شکل ۱۴.۴: Data Raw with ResNet of Matrix Confusion

شکل ۱۶.۴: Models the of Matrices Confusion

۷.۴ نتایج تاثیر شبیه سازی شرایط جوی مختلف بر روی تصاویر

در بخش های قبلی توضیح داده شد که داده ها به طور متوازن و با توزیع نا یکسان آماده شدند. برای این منظور، در راستای اصلاح توزیع داده ها و رسیدن به تعادل مطلوب، شرایط مختلفی مورد بررسی قرار گرفت. این شرایط شامل تغییرات در تعداد کلاس ها، تنوع اشکال و رنگ ها، و تغییرات معانی علائم بود. هدف اصلی این بخش، شبیه سازی شرایط جوی واقعی بود تا بتوانیم اثر یادگیری مدل هوش مصنوعی را بر اساس داده های اصلاح شده ارزیابی کنیم. هدف اصلی این آزمایش ها، آموزش مدل به گونه ای بود که بتواند در شرایط جوی مختلف (مانند مه، باران، برف و...) عملکرد مناسبی داشته باشد. به طور خاص، سعی کردیم تأثیرات شرایط جوی نظیر تغییر رنگ به دلیل نور خورشید، سفید شدن تابلوها با برف، و کاهش دید در شرایط مه و باران را شبیه سازی کنیم. این گونه مدل می تواند عملکرد انسانی را که به طور طبیعی این تغییرات را تشخیص می دهد، شبیه سازی کند.



شکل ۷.۴: تصویر نمونه هایی از اعمال باران، برف، مه، باد و نور زیاد خورشید را مشاهده میکنید

پیاده سازی و شرایط آزمایشی

در این مرحله، برای بررسی دقیق تر عملکرد مدل، شرایط جوی مختلف به صورت مستقل بر روی داده ها اعمال شد. به عنوان مثال، در شرایط بارانی تنها افکت باران به تصاویر اعمال شد و هیچ گونه شرایط جوی

دیگر مانند باد در نظر گرفته نشد. هدف در این مرحله، ساده‌سازی شرایط آزمایشی بود تا بتوانیم اثر هر شرایط جوی به‌طور مستقل بررسی کنیم. هر چند که در خیلی از حالت‌ها احتمال وجود بیش از یک مورد از این حالت‌ها وجود دارد. این کار به ما این امکان را می‌دهد که مدل را در برابر هر یک از این شرایط به‌طور مجزا تست کرده و تأثیر آنها را به‌دقت اندازه‌گیری کنیم.

۱.۷.۴ نتایج و مقایسه

در اینجا درک تأثیر یادگیری از این تصاویر، اول مدل آموزش دیده با داده‌های اولیه را با یک مجموعه آزمایشی تست کردیم که شامل حدود

در آزمایش اول که برای آموزش مدل با داده‌های اولیه انجام شد، نتایج به‌دست آمده برای دقت آموزش ۶۷۴۵.۰ و خطا ۶۵۳.۱ بود. همچنین برای داده‌های اعتبارسنجی، دقت ۶۹۲۹.۰ و خطا ۹۹۶۵.۰ به‌دست آمد، و بالاترین دقت اعتبارسنجی ۷۰۲۹.۰ بود. در تحلیل این نتایج، مشاهده شد که عملکرد مدل نسبت به آزمایشات قبلی که بر روی داده‌های معمولی انجام شده بود، ضعیف‌تر است و این ممکن است به دلایلی مانند تغییرات داده‌ها یا پارامترهای مدل مرتبط باشد. در آزمایش دوم، حدود ۲۰ درصد از تصاویر به‌طور تصادفی فیلتر شدند و پس از آموزش مدل، نتایج به‌صورت زیر به‌دست آمد: دقت آموزش ۸۳۹.۰ و خطا ۹۳۸۸.۰ و برای داده‌های اعتبارسنجی، دقت ۸۱۰۲.۰ و خطا ۸۲۴۹.۰ به‌دست آمد. همچنین، بالاترین دقت اعتبارسنجی در این آزمایش به ۸۳۹.۰ رسید.

تأثیرات شرایط جوی مختلف را بر روی عملکرد مدل دید. این نتایج نشان می‌دهند که مدل توانسته است تا حد زیادی با شرایط جوی مختلف سازگار شود و عملکردی مشابه انسان در تشخیص تغییرات محیطی ارائه دهد.

۲.۷.۴ پیاده‌سازی فیلترهای محیطی در تصاویر و نحوه عملکرد آنها

برای پیاده‌سازی فیلترهای مختلف محیطی بر روی تصاویر و بررسی عملکرد آنها، از کتابخانه‌ی ^{۳۴} برای اعمال تکنیک‌های افزایش داده استفاده کردیم. برای شبیه‌سازی شرایط مختلف محیطی بر روی تصاویر، از مجموعه‌ای از فیلترها استفاده می‌شود. به عنوان مثال، برای شبیه‌سازی باران، از دو فیلتر بلور گوسی و نویز گوسی بهره می‌بریم. فیلتر بلور گوسی به طور خاص برای شبیه‌سازی افکت‌های مه‌آلود یا بارانی به کار می‌رود، زیرا با اعمال تاری بر روی تصویر، جزئیات کمتری قابل مشاهده خواهد بود که مشابه به محدود شدن دید در هنگام بارش باران است. فیلتر نویز گوسی نیز برای اضافه کردن نویز به تصویر استفاده می‌شود که مشابه باران است و باعث ایجاد ناپایداری و تاری در تصویر می‌شود، و به مدل کمک می‌کند تا ویژگی‌های مهم را حتی در شرایط نویزی شبیه‌سازی شده یاد بگیرد. در شبیه‌سازی برف، از فیلتر تصادفی برف استفاده می‌شود. این فیلتر باعث اضافه کردن افکت برف به تصویر می‌شود و با استفاده از پارامترهایی مانند ضریب روشنایی برای روشن‌تر کردن برف‌ها و حد پایین و حد بالای نقطه برف برای تنظیم درصد پوشش برف، تصویر را تغییر می‌دهد. برای شبیه‌سازی مه، از فیلتر بلور گوسی بیشتر استفاده می‌شود تا تصویری که تحت تأثیر مه تاری می‌خورد، شبیه‌سازی شود. این فیلتر باعث کاهش کنتراست و وضوح تصویر می‌شود، که به طور دقیق شرایط دید در مه را شبیه‌سازی می‌کند. در شبیه‌سازی باد، فیلتر تغییر الاستیک به کار می‌رود که باعث ایجاد انحراف در تصویر می‌شود. این تغییرات الاستیک به طور مشابه باعث شبیه‌سازی حرکت اشیاء تحت تأثیر باد می‌گردد. در نهایت، برای شبیه‌سازی نور خورشید، فیلتر تغییر روشنایی و کنتراست به تصویر اعمال می‌شود. این تغییرات می‌تواند تأثیرات نور خورشید را در تصاویر شبیه‌سازی کند و باعث ایجاد تابش یا سایه‌ها در تصویر شود. این فیلترها به طور کلی برای شبیه‌سازی شرایط مختلف محیطی و آموزش مدل‌ها در شرایط واقعی استفاده می‌شوند تا عملکرد بهتری در محیط‌های واقعی داشته باشند.

³⁴alumentations

۳.۷.۴ نحوه اجرای فیلترها

در کد ارائه شده، ابتدا شرایط محیطی مختلفی همچون باران، برف، مه، باد و نور خورشید در یک دیکشنری به نام conditions تعریف می‌شوند. سپس، بر اساس مقادیر این شرایط، فیلترهای مناسب به تصویر اعمال می‌گردند. برای هرکدام از این شرایط، فیلترهای مرتبط به عنوان افزونه‌هایی به یک پایپلاین افزایش داده اضافه می‌شوند. در نهایت، تصویر تحت تأثیر این تغییرات قرار می‌گیرد و به طور مصنوعی شرایط محیطی مختلف را شبیه‌سازی می‌کند. این فرآیند به منظور آموزش مدل‌ها تحت شرایط متنوع محیطی انجام می‌شود، تا مدل‌ها قادر به یادگیری ویژگی‌ها و الگوهای مختلف در محیط‌های چالش برانگیز باشند.

۴.۷.۴ خلاصه عملکرد فیلترها

این فیلترها به طور دقیق شرایط محیطی مختلف را به تصویر اعمال می‌کنند: باران: با استفاده از اعمال تاری و اضافه کردن نویز گوسی شبیه‌سازی می‌شود، که موجب کاهش وضوح و ایجاد افکت‌های مشابه باران می‌شود. برف: با اعمال افکت‌های برفی و تغییرات در روشنایی تصویر شبیه‌سازی می‌شود. این فرآیند برای شبیه‌سازی تصاویر برفی با ویژگی‌های خاص همچون پراکندگی نور در برف و تغییرات کنتراست طراحی شده است. مه: با استفاده از افزایش تاری تصویر (مانند بلور گوسی) شبیه‌سازی می‌شود، که باعث کاهش کنتراست و وضوح تصویر می‌گردد، مشابه شرایط دید در مه. باد: با اعمال تغییرات الاستیک در تصویر شبیه‌سازی می‌شود، که به طور موثر انحرافات ناشی از حرکت و وزش باد در محیط را نشان می‌دهد. نور خورشید: با تغییرات در روشنایی و کنتراست تصویر، به گونه‌ای که تأثیرات تابش نور خورشید و سایه‌ها را شبیه‌سازی کند. این فیلترها نه تنها به شبیه‌سازی شرایط محیطی متنوع کمک می‌کنند، بلکه باعث می‌شوند تا مدل‌ها به طور مؤثرتری تحت شرایط محیطی مختلف آموزش ببینند. این امر موجب می‌شود که مدل‌ها در دنیای واقعی عملکرد بهتری داشته باشند و توانایی بالاتری در پیش‌بینی و تحلیل داده‌ها از خود نشان دهند.

